

PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE

DEPARTAMENTO DE CIENCIA DE LA COMPUTACIÓN

APUNTE IIC2223

---

# Teoría de Autómatas y Lenguajes Formales

---

*Autor*  
Cristóbal ROJAS

*En base a apuntes de*  
Prof. Cristian RIVEROS

3 de diciembre de 2022



# Índice

<b>1. Lenguajes regulares</b>	<b>3</b>
1.1. Palabras y autómatas . . . . .	3
1.1.1. Palabras . . . . .	3
1.1.2. Autómatas . . . . .	4
1.2. Construcciones de autómatas . . . . .	6
1.2.1. Autómatas con función parcial de transición . . . . .	6
1.2.2. Operaciones de conjuntos . . . . .	7
1.3. No-determinismo . . . . .	9
1.3.1. Definición de un NFA . . . . .	9
1.3.2. Comparación con DFA . . . . .	11
1.4. Expresiones regulares . . . . .	13
1.5. Autómatas con transiciones sin lectura . . . . .	15
1.5.1. e-NFA . . . . .	15
1.5.2. NFA versus e-NFA . . . . .	17
1.6. Teorema de Kleene . . . . .	19
1.6.1. Desde Expresiones a Autómatas . . . . .	19
1.6.2. Desde Autómatas a Expresiones . . . . .	20
<b>2. Propiedades de lenguajes regulares</b>	<b>23</b>
2.1. Lema de bombeo . . . . .	23
2.2. Minimización de autómatas . . . . .	26
2.2.1. Colapsar estados . . . . .	27
2.2.2. Algoritmo de minimización . . . . .	28
2.3. Teorema de Myhill-Nerode . . . . .	30
2.3.1. Relaciones de Myhill-Nerode . . . . .	30
2.3.2. Camino al teorema . . . . .	31
2.4. Autómatas en dos direcciones . . . . .	32
<b>3. Algoritmos para lenguajes regulares</b>	<b>33</b>
3.1. Evaluación de expresiones regulares . . . . .	33
3.2. Transductores . . . . .	33
3.3. Análisis léxico . . . . .	33
3.4. Algoritmo de Knuth-Morris-Prat . . . . .	33
<b>4. Lenguajes libres de contexto</b>	<b>34</b>
4.1. Gramáticas libres de contexto . . . . .	34
4.2. Simplificación de gramáticas . . . . .	34
4.3. Forma normal de Chomsky . . . . .	34
4.4. Lema de bombeo para lenguajes libres de contexto . . . . .	34
4.5. Algoritmo CKY . . . . .	34
<b>5. Algoritmos para lenguajes libres de contexto</b>	<b>35</b>
5.1. Autómatas apiladores . . . . .	35
5.1.1. Versión normal . . . . .	35
5.1.2. Versión alternativa . . . . .	37
5.2. Autómatas apiladores vs gramáticas libres de contexto . . . . .	39
5.2.1. Desde CFG a PDA . . . . .	40
5.2.2. Desde PDA a CFG . . . . .	41
5.3. Parsing: cómputo de First y Follow . . . . .	43
5.3.1. Prefijos . . . . .	45
5.3.2. First y Follow . . . . .	46
5.3.3. Calcular First . . . . .	47

5.3.4. Calcular Follow . . . . .	48
5.4. Gramáticas LL . . . . .	49
5.4.1. Definición Gramáticas LL . . . . .	50
5.4.2. Caracterización LL . . . . .	52
5.5. Parsing con gramáticas LL(k) . . . . .	54
5.5.1. Algunas consideraciones . . . . .	54
5.5.2. Parsing de LL(k) . . . . .	57
<b>6. Extracción de información</b>	<b>61</b>
6.1. Extracción . . . . .	61
6.2. Enumeración de resultados: Autómatas con anotaciones . . . . .	61

# 1. Lenguajes regulares

## 1.1. Palabras y autómatas

### 1.1.1. Palabras

**Definiciones.** Consideremos que:

- ♦ Un **alfabeto**  $\Sigma$  es con conjunto finito.
- ♦ Un elemento de  $\Sigma$  lo llamaremos una **letra** o **símbolo**.
- ♦ Una **palabra** o **string** sobre  $\Sigma$  es una secuencia finita de letras en  $\Sigma$ .

#### Ejemplo 1.1

- $\Sigma = \{a, b, c\}$

- Palabras sobre  $\Sigma$ :

$aaaaabb, bcaabab, a, bbbbbb, \dots$

- ♦ El largo  $|w|$  de una palabra  $w$  es el número de letras.

$$|w| \stackrel{\text{def}}{=} \# \text{ de letras en } w$$

- ♦ Denotaremos  $\epsilon$  como la **palabra sin símbolos** de largo 0.

$$|\epsilon| \stackrel{\text{def}}{=} 0$$

- ♦ Denotaremos por  $\Sigma^*$  como el **conjunto de todas las palabras** sobre  $\Sigma$ .

#### Ejemplo 1.2

Para  $\Sigma = \{0, 1\}$ :

- $|00011001| = 8$
- $\Sigma^* =$  todas las palabras posibles formadas por 0s y 1s.

**Definición.** Dados dos palabras  $u, v \in \Sigma^*$  tal que  $u = a_1 \dots a_n$  y  $v = b_1 \dots b_m$ :

$$u \cdot v \stackrel{\text{def}}{=} a_1 \dots a_n b_1 \dots b_m$$

Decimos que  $u \cdot v$  es la palabra “ **$u$  concatenada con  $v$** ”.

#### Ejemplo 1.3

Para  $\Sigma = \{0, 1, 2, \dots, 9\}$ :

- ♦  $0123 \cdot 9938 = 01239938$  y  $3493 \cdot \epsilon = 3493$

**Propiedades de concatenación.** La concatenación cumple:

- ♦ **Asociatividad:**  $(u \cdot v) \cdot w = u \cdot (v \cdot w)$
- ♦ **Largo:**  $|u \cdot v| = |u| + |v|$
- ♦ ¿Cumple conmutatividad? No. Por ejemplo, si  $u = ab$  y  $v = bb$ , entonces  $u \cdot v = abbb \neq bbab = v \cdot u$ .

**Definición.** Sea  $\Sigma$  un alfabeto y  $L \subseteq \Sigma^*$ . Decimos que  $L$  es un **lenguaje** sobre el alfabeto  $\Sigma$ .

#### Ejemplo 1.4

Sea  $\Sigma = \{a, b\}$ :

- ♦  $L_0 = \{\epsilon, a, aa, b, aa\}$
- ♦  $L_1 = \{\epsilon, b, bb, bbb, bbbb, \dots\}$
- ♦  $L_2 = \{w \mid \exists u \in L_1, w = a \cdot u\}$
- ♦  $L_3 = \{w \mid \exists u, v \in \Sigma^*, w = u \cdot abba \cdot v\}$
- ♦  $L_4 = \{w \mid \exists u \in \Sigma^*, w = u \cdot u\}$

Un **lenguaje** puede ser visto como una **propiedad** de palabras.

**Convenciones.** Durante todo este texto:

- ♦ Para **letras** se usarán los símbolos:  $a, b, c, d, e, \dots$
- ♦ Para **palabras** se usarán los símbolos:  $w, u, v, x, y, z, \dots$
- ♦ Para **alfabetos** se usarán los símbolos:  $\Sigma, \Gamma, \dots$
- ♦ Para **lenguajes** se usarán los símbolos:  $L, M, N, \dots$
- ♦ Para **números** se usarán los símbolos:  $i, j, k, l, m, n, \dots$

#### 1.1.2. Autómatas

Una autómata **finito** es:

- ♦ Un modelo de computación sencillo, basado en una cantidad **finita** de memoria.
- ♦ Procesa cada **palabra** de principio a fin en **una sola pasada**.
- ♦ Al terminar, el autómata decide si **acepta** o **rechaza** el input.

Usaremos los autómatas finitos para definir **lenguajes**.

**Definición.** Un autómata finito determinista (DFA) es una tupla:

$$\mathcal{A} = (Q, \Sigma, \delta, q_0, F)$$

- ♦  $Q$  es un conjunto finito de **estados**.
- ♦  $\Sigma$  es el alfabeto del **input**.
- ♦  $\delta : Q \times \Sigma \rightarrow Q$  es la función de **transición**.
- ♦  $q_0 \in Q$  es el **estado inicial**.
- ♦  $F \subseteq Q$  es el conjunto de **estados finales** (o aceptación).

**Ejemplo 1.5**

$$\diamond Q = \{0, 1, 2\}$$

$$\diamond \Sigma = \{a, b\}$$

$\diamond \delta : Q \times \Sigma \rightarrow Q$  se define como:

$$\delta(0, a) = 1$$


$$\delta(1, a) = 2$$

$$\delta(2, a) = 2$$

$$\delta(q, b) = q \quad \forall q \in \{0, 1, 2\}$$

$$\diamond q_0 = 0$$

$$\diamond F = \{2\}$$




**Ejecución.** Sea  $\mathcal{A} = (Q, \Sigma, \delta, q_0, F)$  un DFA y  $w = a_1 a_2 \dots a_n \in \Sigma^*$  un input. Una **ejecución** (o *run*)  $\rho$  de  $\mathcal{A}$  sobre  $w$  es una secuencia:

$$\rho : p_0 \xrightarrow{a_1} p_1 \xrightarrow{a_2} p_2 \xrightarrow{a_3} \dots \xrightarrow{a_n} p_n$$

donde  $p_0 = q_0$  y para todo  $i \in \{0, 1, \dots, n-1\}$  se cumple que  $\delta(p_i, a_{i+1}) = p_{i+1}$ .

Una ejecución  $\rho$  de  $\mathcal{A}$  sobre  $w$  es de **aceptación** si  $p_n \in F$ .

**Ejemplo 1.6**

$\diamond$  ¿Cuál es la ejecución de  $\mathcal{A}$  sobre  $bbab$ ?

$\rho : 0 \xrightarrow{b} 0 \xrightarrow{b} 0 \xrightarrow{a} 1 \xrightarrow{b} 1$ . La ejecución **no** es de aceptación ya que no termina en un estado final.

$\diamond$  ¿Cuál es la ejecución de  $\mathcal{A}$  sobre  $abab$ ?

$\rho : 0 \xrightarrow{a} 1 \xrightarrow{b} 1 \xrightarrow{a} 2 \xrightarrow{b} 2$ . La ejecución **si** es de aceptación ya que termina en un estado final.

**Aceptación.** Sea  $\mathcal{A} = (Q, \Sigma, \delta, q_0, F)$  un DFA y  $w \in \Sigma^*$ . Decimos que  $\mathcal{A}$  **acepta**  $w$  si la ejecución de  $\mathcal{A}$  sobre  $w$  es de aceptación. Al contrario, decimos que  $\mathcal{A}$  **rechaza**  $w$  si la ejecución de  $\mathcal{A}$  sobre  $w$  NO es de aceptación.

El **lenguaje aceptado** por  $\mathcal{A}$  se define como:

$$\mathcal{L}(\mathcal{A}) = \{w \in \Sigma^* \mid \mathcal{A} \text{ acepta } w\}$$

Un lenguaje  $L \subseteq \Sigma^*$  se dice **regular** si, y sólo si, **existe** un autómata finito determinista  $\mathcal{A}$  tal que

$$L = \mathcal{L}(\mathcal{A})$$

## 1.2. Construcciones de autómatas

Veremos una definición alternativa al autómata visto en la sección anterior.

### 1.2.1. Autómatas con función parcial de transición

**Definición.** Un autómata finito determinista con **función parcial de transición** (DFAp) es una tupla:

$$\mathcal{A} = (Q, \Sigma, \gamma, q_0, F)$$

- ♦  $Q$  es un conjunto finito de estados.
- ♦  $\Sigma$  es el alfabeto del input.
- ♦  $\gamma : Q \times \Sigma \rightarrow Q$  es una **función parcial de transición**.
- ♦  $q_0 \in Q$  es el estado inicial.
- ♦  $F \subseteq Q$  es el conjunto de estados finales (o aceptación).

**Ejecución.** Sea  $w = a_1 a_2 \dots a_n \in \Sigma^*$ . De igual manera que un DFA, una **ejecución** (o *run*)  $\rho$  de  $\mathcal{A}$  sobre  $w$  es una secuencia:

$$\rho : p_0 \xrightarrow{a_1} p_1 \xrightarrow{a_2} p_2 \dots \xrightarrow{a_n} p_n$$


donde  $p_0 = q_0$  y para todo  $i \in \{0, \dots, n-1\}$  está definido  $\gamma(p_i, a_{i+1}) = p_{i+1}$ .

Una ejecución  $\rho$  de  $\mathcal{A}$  sobre  $w$  es de **aceptación** si  $p_n \in F$ . Notemos que ahora una palabra puede NO tener una ejecución.

**Aceptación.** Sea  $\mathcal{A}$  un DFAp y  $w \in \Sigma^*$ . Decimos que  $\mathcal{A}$  **acepta**  $w$  si **existe una ejecución** de  $\mathcal{A}$  sobre  $w$  que es de aceptación. También, el **lenguaje aceptado** por  $\mathcal{A}$  se define como:

$$\mathcal{L}(\mathcal{A}) = \{w \in \Sigma^* \mid \mathcal{A} \text{ acepta } w\}$$

#### Ejemplo 1.7



**¿DFA  $\neq$  DFAp?** Establezcamos una proposición. Para todo autómata  $\mathcal{A}$  con función parcial de transición, existe un autómata  $\mathcal{A}'$  (con función total de transición) tal que:

$$\mathcal{L}(\mathcal{A}) = \mathcal{L}(\mathcal{A}')$$

En otras palabras, DFA  $\equiv$  DFAp.

**Demostración.** Sea  $\mathcal{A} = (Q, \Sigma, \gamma, q_0, F)$  un autómata con función parcial de transición. Sea  $q_s$  un **nuevo estado** tal que  $q_s \notin Q$ . Construimos el DFA  $\mathcal{A}' = (Q \cup \{q_s\}, \Sigma, \delta', q_0, F)$  tal que:

$$\delta'(p, a) = \begin{cases} \gamma(p, a) & \text{si } p \neq q_s \text{ y } (p, a) \in \text{dom}(\gamma) \\ q_s & \text{si no} \end{cases}$$

para todo  $p \in Q \cup \{q_s\}$  y  $a \in \Sigma$ . Queremos demostrar que  $\mathcal{L}(\mathcal{A}) = \mathcal{L}(\mathcal{A}')$ .

**Dem.**  $\mathcal{L}(\mathcal{A}) \subseteq \mathcal{L}(\mathcal{A}')$ . Sea  $w = a_1 \dots a_n \in \mathcal{L}(\mathcal{A})$ . Entonces, existe una ejecución de aceptación  $\rho$  de  $\mathcal{A}$  sobre  $w$ :

$$\rho : p_0 \xrightarrow{a_1} p_1 \xrightarrow{a_2} p_2 \dots \xrightarrow{a_n} p_n$$

donde  $p_0 = q_0$ , para todo  $i \in \{0, \dots, n-1\}$  está definido  $\gamma(p_i, a_{i+1}) = p_{i+1}$  y  $p_n \in F$ . Como  $\delta'(p_i, a_{i+1}) = \gamma(p_i, a_{i+1})$  para todo  $i \in \{0, \dots, n-1\}$  (por la definición de  $\delta'$ ), entonces  $\rho$  es también una ejecución de aceptación de  $\mathcal{A}'$  sobre  $w$ . Por lo tanto,  $w \in \mathcal{L}(\mathcal{A}')$ .

**Dem.**  $\mathcal{L}(\mathcal{A}') \subseteq \mathcal{L}(\mathcal{A})$ . Sea  $w = a_1 \dots a_n \in \mathcal{L}(\mathcal{A}')$ . Entonces, existe una ejecución de aceptación  $\rho$  de  $\mathcal{A}'$  sobre  $w$ :

$$\rho : p_0 \xrightarrow{a_1} p_1 \xrightarrow{a_2} p_2 \dots \xrightarrow{a_n} p_n$$

donde  $p_0 = q_0$ , para todo  $i \in \{0, \dots, n-1\}$  tenemos  $\gamma'(p_i, a_{i+1}) = p_{i+1}$  y  $p_n \in F$ . Demostraremos que  $p_i \neq q_s$  para todo  $i \in \{0, \dots, n\}$ . Por **contradicción**, suponga que existe  $i$  tal que  $p_i = q_s$ . entonces, tenemos que  $p_{i+1} = q_s$ . Por **inducción**, podemos demostrar que  $p_j = q_s$  para todo  $j \geq i$ , y así, podemos concluir que  $p_n = q_s$ , llevándonos a una contradicción. Como  $p_i \neq q_s$  para todo  $i \in \{0, \dots, n\}$ , tenemos que:

$$\delta'(p_i, a_{i+1}) = \gamma(p_i, a_{i+1}) \quad \forall i \in \{0, 1, \dots, n-1\}$$

y entonces  $\rho$  es una **ejecución de aceptación** de  $\mathcal{A}$  sobre  $w$ . Por lo tanto, concluimos que  $w \in \mathcal{L}(\mathcal{A})$ . ■

**Advertencia.** Desde ahora, se utilizarán autómatas con funciones **totales** de transición, pero sin pérdida de generalidad, en algunos ejemplos habrán autómatas con funciones **parciales** de transición por simplicidad.

### 1.2.2. Operaciones de conjuntos

**Definiciones.** Dado dos lenguajes  $L, L' \subseteq \Sigma^*$  se define:

$$\begin{aligned} L^C &= \{w \in \Sigma^* \mid w \notin L\} \\ L \cap L' &= \{w \in \Sigma^* \mid w \in L \wedge w \in L'\} \\ L \cup L' &= \{w \in \Sigma^* \mid w \in L \vee w \in L'\} \end{aligned}$$

Dado dos autómatas  $\mathcal{A}$  y  $\mathcal{A}'$ :

1. ¿Existe un autómata  $\mathcal{B}$  tal que  $\mathcal{L}(\mathcal{B}) = \mathcal{L}(\mathcal{A})^C$ ?
2. ¿Existe un autómata  $\mathcal{B}$  tal que  $\mathcal{L}(\mathcal{B}) = \mathcal{L}(\mathcal{A}) \cap \mathcal{L}(\mathcal{A}')$ ?
3. ¿Existe un autómata  $\mathcal{B}$  tal que  $\mathcal{L}(\mathcal{B}) = \mathcal{L}(\mathcal{A}) \cup \mathcal{L}(\mathcal{A}')$ ?



**Construcción de  $\mathcal{L}(\mathcal{A})^C$ .** Dado un autómata  $\mathcal{A} = (Q, \Sigma, \delta, q_0, F)$ , definimos el autómata:

$$\mathcal{A}^C = (Q, \Sigma, \delta, q_0, Q \setminus F)$$

### Teorema 1

Para todo autómata  $\mathcal{A}$ , se tiene que  $\mathcal{L}(\mathcal{A})^C = \mathcal{L}(\mathcal{A}^C)$ .

**Producto de autómatas.** Suponga que:


$$\begin{aligned}\mathcal{A} &= (Q, \Sigma, \delta, q_0, F) \\ \mathcal{A}' &= (Q', \Sigma, \delta', q'_0, F')\end{aligned}$$

y considere una palabra  $w \in \Sigma^*$ . ¿Cómo ejecutamos ambos autómatas sobre  $w$  al **mismo tiempo**? La idea es ejecutar  $\mathcal{A}$  y  $\mathcal{A}'$  **en paralelo**. Así, definimos el **producto** entre  $\mathcal{A}$  y  $\mathcal{A}'$  como el autómata  $\mathcal{A} \times \mathcal{A}' = (Q^\times, \Sigma, \delta^\times, q_0^\times, F^\times)$  tal que:

- ♦  $Q^\times = Q \times Q' = \{(q, q') \mid q \in Q \wedge q' \in Q'\}$
- ♦  $\delta^\times((q, q'), a) = (\delta(q, a), \delta'(q', a))$
- ♦  $q_0^\times = (q_0, q'_0)$
- ♦  $F^\times = F \times F'$

### Ejemplo 1.8

Todas las palabras sobre  $\{a, b\}$  con una cantidad par de  $a$ -letras tal que no hay dos  $a$ -letras seguidas.



### Teorema 2

Para todo par de autómatas  $\mathcal{A}$  y  $\mathcal{A}'$  se tiene que

$$\mathcal{L}(\mathcal{A} \times \mathcal{A}') = \mathcal{L}(\mathcal{A}) \cap \mathcal{L}(\mathcal{A}')$$

**Demostración teorema 2.** Solo se demostrará que  $\mathcal{L}(\mathcal{A}) \cap \mathcal{L}(\mathcal{A}') \subseteq \mathcal{L}(\mathcal{A} \times \mathcal{A}')$ , la otra dirección queda propuesta para el lector.

Sea  $w = a_1 \dots a_n \in \mathcal{L}(\mathcal{A}) \cap \mathcal{L}(\mathcal{A}')$ . Entonces  $w \in \mathcal{L}(\mathcal{A})$  y  $w \in \mathcal{L}(\mathcal{A}')$ . Existen ejecuciones de aceptación  $\rho$  y  $\rho'$  de  $\mathcal{A}$  y  $\mathcal{A}'$  sobre  $w$ , respectivamente:

$$\rho : p_0 \xrightarrow{a_1} p_1 \xrightarrow{a_2} \dots \xrightarrow{a_n} p_n \quad \rho' : p'_0 \xrightarrow{a_1} p'_1 \xrightarrow{a_2} \dots \xrightarrow{a_n} p'_n$$

- ♦  $p_0 = q_0$  y  $p'_0 = q'_0$ .
- ♦  $\delta(p_{i-1}, a_i) = p_i$  y  $\delta'(p'_{i-1}, a_i) = p_i$  para todo  $i \in \{1, \dots, n\}$ .
- ♦  $p_n \in F$  y  $p'_n \in F'$ .

Por definición, tenemos que:  $\rho^\times : (p_0, p'_0) \xrightarrow{a_1} (p_1, p'_1) \xrightarrow{a_2} \dots \xrightarrow{a_n} (p_n, p'_n)$

- ♦  $(p_0, p'_0) = (q_0, q'_0)$ .
- ♦  $(p_i, p'_i) = (\delta(p_{i-1}, a_i), \delta'(p'_{i-1}, a_i)) = \delta^\times((p_{i-1}, p'_{i-1}), a_i) \forall i \in \{1, \dots, n\}$ .
- ♦  $(p_n, p'_n) \in F \times F'$ .

Por lo tanto,  $\rho^\times$  es una ejecución de  $\mathcal{A} \times \mathcal{A}'$  sobre  $w$  y  $w \in \mathcal{L}(\mathcal{A} \times \mathcal{A}')$ . ■

**Unión de autómatas.** Sabemos que

$$\mathcal{L}(\mathcal{A}) \cup \mathcal{L}(\mathcal{A}') = \left( \mathcal{L}(\mathcal{A})^C \cap \mathcal{L}(\mathcal{A}')^C \right)^C$$

Para calcular el autómata que acepta el lenguaje  $\mathcal{L}(\mathcal{A}) \cup \mathcal{L}(\mathcal{A}')$ :

1. Complementamos  $\mathcal{A}$  y  $\mathcal{A}'$ .
2. Intersectamos  $\mathcal{A}^C$  y  $(\mathcal{A}')^C$ .
3. Complementamos  $\mathcal{A}^C \times (\mathcal{A}')^C$ .

### 1.3. No-determinismo

*“Indeterminism is the concept that events (certain events, or events of certain types) are not caused deterministically (cf. causality) by prior events. It is the opposite of **determinism** and related to chance. It is highly relevant to the philosophical problem of **free will**.”* - Wikipedia.

#### 1.3.1. Definición de un NFA

**Definición.** Un autómata finito **no-determinista** (NFA) es una estructura:

$$\mathcal{A} = (Q, \Sigma, \Delta, I, F)$$

- ♦  $Q$  es un conjunto finito de estados.
- ♦  $\Sigma$  es el alfabeto del input.
- ♦  $F \subseteq Q$  es el conjunto de estados finales (o aceptación).
- ♦  $\Delta \subseteq Q \times \Sigma \times Q$  es la **relación de transición**.
- ♦  $I \subseteq Q$  es un **conjunto de estados iniciales**.

**Ejemplo 1.9**

♦  $Q = \{0, 1, 2\}$ ,  $\Sigma = \{a, b\}$ ,  $I = \{0, 1\}$ ,  $F = \{2\}$

♦  $\Delta \subseteq Q \times \Sigma \times Q$  se define como:

$(0, a, 0) \in \Delta$


$(0, a, 1) \in \Delta$

$(0, b, 0) \in \Delta$

$(1, b, 2) \in \Delta$

$(2, a, 2) \in \Delta$

$(2, b, 2) \in \Delta$



**Ejecución.** Sea  $\mathcal{A} = (Q, \Sigma, \Delta, I, F)$  un NFA y  $w = a_1 a_2 \dots a_n \in \Sigma^*$  el input. Una **ejecución** (o *run*)  $\rho$  de  $\mathcal{A}$  sobre  $w$  es una secuencia:

$$\rho : p_0 \xrightarrow{a_1} p_1 \xrightarrow{a_2} \dots \xrightarrow{a_n} p_n$$

donde  $p_0 \in I$  y para todo  $i \in \{0, \dots, n-1\}$ , se tiene que  $(p_i, a_{i+1}, p_{i+1}) \in \Delta$ .

Una ejecución  $\rho$  de  $\mathcal{A}$  sobre  $w$  es de **aceptación** si  $p_n \in F$ .

**Aceptación.** Decimos que  $\mathcal{A}$  **acepta**  $w$  si **existe** una ejecución de  $\mathcal{A}$  sobre  $w$  que es de aceptación. Por otro lado, decimos que  $\mathcal{A}$  **rechaza** si **todas** las ejecuciones de  $\mathcal{A}$  sobre  $w$  NO son de aceptación. Además, el **lenguaje aceptado** por  $\mathcal{A}$  se define como:

$$\mathcal{L}(\mathcal{A}) = \{w \in \Sigma^* \mid \mathcal{A} \text{ acepta } w\}$$

**Interpretación.** Las siguientes interpretaciones pueden ayudar a entender mejor un NFA:

1.  $\Delta \subseteq Q \times \Sigma \times Q$  es la **relación de transición**.

“(q, a, p) ∈ Δ entonces existe una transición desde q a p al leer a”.

2.  $I \subseteq Q$  es un **conjunto de estados iniciales**.

“p ∈ I entonces p es un posible estado inicial del autómata”

1'.  $\Delta : Q \times \Sigma \rightarrow 2^Q$  es una **función de transición**.

“q ∈ Δ(p, a) entonces q es un posible estado que puedo llegar desde p al leer a”.

Esta interpretación es más común encontrarla en libros sobre teoría de autómatas.

Además, el **no-determinismo** puede ser visto como:

1. Paralelización infinita, es decir, cada ejecución es un *thread* distinto.

2. “Guessing and Verifying” (adivinar y verificar).

El no-determinismo NO debe ser visto como:

♦ Explicitamente como el **indeterminismo** o “libre albedrío”. Para un input, un NFA siempre produce el mismo resultado.

♦ Comportamiento **aleatorio** del autómata.




Figura 1: Interpretación del no-determinismo

### 1.3.2. Comparación con DFA

A continuación, veremos que un autómata finito determinista (DFA) puede almacenar **todas** las ejecuciones de un NFA. A este proceso se le conoce como **determinización**.

#### Teorema 3


Para todo autómata finito no-determinista  $\mathcal{A}$ , existe un autómata determinista  $\mathcal{A}'$  tal que

$$\mathcal{L}(\mathcal{A}) = \mathcal{L}(\mathcal{A}')$$

En otras palabras,  $DFA \equiv NFA$ .

**Idea.** Primero, pensemos en la idea de determinización: “almacenar en el autómata determinista todos los estados actuales de las ejecuciones en curso (sin repetidos)”.

#### Ejemplo 1.10



**Formalización.** Para un autómata no-determinista  $\mathcal{A} = (Q, \Sigma, \Delta, I, F)$ , definimos el autómata determinista (determinización de  $\mathcal{A}$ ):

$$\mathcal{A}^{\text{det}} = (2^Q, \Sigma, \delta^{\text{det}}, q_0^{\text{det}}, F^{\text{det}})$$

♦  $2^Q = \{S \mid S \subseteq Q\}$  es el conjunto potencia de  $Q$ .

♦  $q_0^{\text{det}} = I$ .

♦  $\delta^{\text{det}} : 2^Q \times \Sigma \rightarrow 2^Q$  tal que:

$$\delta^{\text{det}}(S, a) = \{q \in Q \mid \exists p \in S. (p, a, q) \in \Delta\}$$

♦  $F^{\text{det}} = \{S \in 2^Q \mid S \cap F \neq \emptyset\}$ , es decir, todos los conjuntos que tengan al menos un estado final.

**Demostración teorema 3.** La determinización puede verse como un **subset construction**. Partamos con  $\mathcal{L}(\mathcal{A}) \subseteq \mathcal{L}(\mathcal{A}^{\text{det}})$ .

Sea  $w = a_1 \dots a_n \in \mathcal{L}(\mathcal{A})$ . Existe una ejecución  $\rho$  de  $\mathcal{A}$  sobre  $w$ :

$$\rho : p_0 \xrightarrow{a_1} p_1 \xrightarrow{a_2} \dots \xrightarrow{a_n} p_n$$

donde  $p_0 = I$ ,  $(p_i, a_{i+1}, p_{i+1}) \in \Delta$  para todo  $i \in \{0, \dots, n-1\}$  y  $p_n \in F$ .

Como  $\mathcal{A}^{\text{det}}$  es determinista, entonces existe una ejecución  $\rho'$  de  $\mathcal{A}^{\text{det}}$  sobre  $w$ :

$$\rho' : S_0 \xrightarrow{a_1} S_1 \xrightarrow{a_2} \dots \xrightarrow{a_n} S_n$$

donde  $S_0 = I$  y  $\delta^{\text{det}}(S_i, a_{i+1}) = S_{i+1}$  para todo  $i \in \{0, \dots, n-1\}$ . Luego, queremos demostrar que  $p_i \in S_i$  para todo  $i \in \{0, \dots, n-1\}$ .

Por **inducción** sobre  $i$ , tenemos que:

♦ **Caso base:**  $p_0 \in S_0$  por definición de  $\mathcal{A}^{\text{det}}$ .

♦ **Inducción:** Suponemos que  $p_i \in S_i$  y demostramos para  $i+1$ . Como sabemos que:

- $\delta^{\text{det}}(S_i, a_{i+1}) = S_{i+1} = \{q \in Q \mid \exists p \in S_i. (p, a, q) \in \Delta\}$  y
- $(p_i, a_{i+1}, p_{i+1}) \in \Delta$

Entonces  $p_{i+1} \in S_{i+1}$ , ya que, si estamos en  $p_i$  leyendo  $a_{i+1}$ , la transición nos dice que pasaremos al estado  $p_{i+1}$  que pertenece a  $S_{i+1}$  por la hipótesis de inducción.

Luego, como  $p_n \in S_n$ , entonces  $S_n \cap F \neq \emptyset$  y así  $S_n \in F^{\text{det}}$ . Por lo tanto,  $w \in \mathcal{L}(\mathcal{A}^{\text{det}})$ .

Ahora, demostramos la otra dirección:  $\mathcal{L}(\mathcal{A}^{\text{det}}) \subseteq \mathcal{L}(\mathcal{A})$ .

Sea  $w = a_1 \dots a_n \in \mathcal{L}(\mathcal{A}^{\text{det}})$ . Existe una ejecución  $\rho$  de  $\mathcal{A}^{\text{det}}$  sobre  $w$ :

$$\rho : S_0 \xrightarrow{a_1} S_1 \xrightarrow{a_2} \dots \xrightarrow{a_n} S_n$$

donde  $S_0 = I$ ,  $\delta^{\text{det}}(S_i, a_{i+1}) = S_{i+1}$  para todo  $i \in \{0, \dots, n-1\}$  y  $S_n \in F^{\text{det}}$ , con  $S_n \cap F \neq \emptyset$ . Buscamos demostrar entonces que para todo  $i \leq n$  y para todo  $p \in S_i$ , existe una ejecución:

$$\rho : p_0 \xrightarrow{a_1} p_1 \xrightarrow{a_2} \dots \xrightarrow{a_i} p_i = p$$

tal que:

1.  $p_0 \in I$ .
2.  $(p_j, a_{j+1}, p_{j+1}) \in \Delta$  para todo  $j \in \{0, \dots, i-1\}$ .

Por **inducción** sobre  $i$ , tenemos que:

♦ **Caso base:** Si  $p \in S_0 = I$ , entonces la ejecución  $\rho : p$  cumple 1. y 2.

♦ **Inducción:** Supongamos que se cumple para todo  $p \in S_i$ . Sea  $q \in S_{i+1}$ . Como  $\delta^{\text{det}}(S_i, a_{i+1}) = S_{i+1} = \{q \in Q \mid \exists p \in S_i. (p, a, q) \in \Delta\}$  y  $q \in S_{i+1}$ , entonces existe  $p \in S_i$  tal que  $(p, a_{i+1}, q) \in \Delta$ .

Por hipótesis de inducción, existe  $\rho : p_0 \xrightarrow{a_1} p_1 \xrightarrow{a_2} \dots \xrightarrow{a_i} p_i = p$  que satisface 1. y 2.

Por lo tanto,  $\rho' : p_0 \xrightarrow{a_1} p_1 \xrightarrow{a_2} \dots \xrightarrow{a_i} p_i \xrightarrow{a_{i+1}} q$  también satisface 1. y 2.

Como lo anterior queda demostrado y como  $S_n \cap F \neq \emptyset$ , para  $p \in S_n \cap F$  existe una ejecución de aceptación de  $\mathcal{A}$  sobre  $w$ . Por lo tanto,  $w \in \mathcal{L}(\mathcal{A})$ . ■

## 1.4. Expresiones regulares

**Definición.**  $R$  es una **expresión regular** sobre  $\Sigma$  si  $R$  es igual a:

1.  $a$ , para alguna letra  $a \in \Sigma$ .
2.  $\epsilon$
3.  $\emptyset$
4.  $(R_1 + R_2)$ , donde  $R_1$  y  $R_2$  son expresiones regulares.
5.  $(R_1 \cdot R_2)$ , donde  $R_1$  y  $R_2$  son expresiones regulares.
6.  $(R_1^*)$ , donde  $R_1$  es una expresión regular. Esta expresión se conoce como **clausura de Kleene**.

Denotaremos como  $\text{ExpReg}$  el conjunto de **todas las expresiones regulares** sobre  $\Sigma$ .

### Ejemplo 1.11

Las siguientes son expresiones regulares sobre  $\Sigma = \{a, b\}$ :

- ♦  $(a + b)$
- ♦  $((a \cdot b) \cdot c)$
- ♦  $(a^*)$
- ♦  $(b \cdot (a^*))$
- ♦  $((a + b)^*)$
- ♦  $((a \cdot ((b \cdot a)^*)) + \epsilon)$
- ♦  $((a \cdot ((b \cdot a)^*)) + \emptyset)$

Para reducir la cantidad de paréntesis, se define el **orden de precedencia**:

1. estrella  $(\cdot)^*$
2. concanetación  $\cdot$
3. unión  $+$

**Semántica.** Para una expresión regular  $R$  cualquiera, se define el lenguaje  $\mathcal{L}(R) \subseteq \Sigma^*$  **inductivamente** como:

1.  $\mathcal{L}(a) = \{a\}$ , para toda letra  $a \in \Sigma$ .
2.  $\mathcal{L}(\epsilon) = \{\epsilon\}$ .
3.  $\mathcal{L}(\emptyset) = \emptyset$ .
4.  $\mathcal{L}(R_1 + R_2) = \mathcal{L}(R_1) \cup \mathcal{L}(R_2)$ , donde  $R_1$  y  $R_2$  son expresiones regulares.
5.  $\mathcal{L}(R_1 \cdot R_2) = \mathcal{L}(R_1) \cdot \mathcal{L}(R_2)$ , donde  $R_1$  y  $R_2$  son expresiones regulares.
6.  $\mathcal{L}(R_1^*) = \bigcup_{k=0}^{\infty} \mathcal{L}(R_1)^k$ , donde  $R_1$  es una expresión regular.

Para el punto 5. y 6., definimos para dos lenguajes  $L_1, L_2 \subseteq \Sigma^*$  el **producto** de  $L_1$  y  $L_2$ :

$$L_1 \cdot L_2 = \{w_1 \cdot w_2 \mid w_1 \in L_1 \wedge w_2 \in L_2\}$$

Además, para un lenguaje  $L \subseteq \Sigma^*$  se define la **potencia** a la  $n \geq 0$ :

$$L^n = \{w_1 \cdot w_2 \dots w_n \mid \forall i \leq n. w_i \in L\}$$

La **potencia** a la 0 se define como  $L^0 = \{\epsilon\}$ .

### Ejemplo 1.12

Se muestran a continuación lenguajes definidos por algunas ExpReg:

- ♦  $\mathcal{L}((a+b)^*) = \{a, b\}^*$
- ♦  $\mathcal{L}((a \cdot b) \cdot (b \cdot a)) = \{abba\}$
- ♦  $\mathcal{L}(a \cdot (b \cdot a) + b \cdot a + (a \cdot b) \cdot a) = \{aba, ba\}$

**Definición.** Decimos que  $R_1$  es **equivalente** a  $R_2$  si, y sólo si,  $\mathcal{L}(R_1) = \mathcal{L}(R_2)$ . Si  $R_1$  es equivalente a  $R_2$ , escribiremos  $R_1 \equiv R_2$ .

**Lema.** Los operadores de unión  $+$  y producto  $\cdot$  son **asociativos**.

$$\begin{aligned} (R_1 + R_2) + R_3 &\equiv R_1 + (R_2 + R_3) \\ (R_1 \cdot R_2) \cdot R_3 &\equiv R_1 \cdot (R_2 \cdot R_3) \end{aligned}$$

La demostración de este lema queda como ejercicio propuesto al lector.

### Ejemplo 1.13

Más lenguajes definidos por algunas ExpReg:

- ♦  $\mathcal{L}(a^* \cdot b \cdot a^*) =$  todas las palabras con una sola  $b$ .
- ♦  $\mathcal{L}((a+b)^* \cdot b \cdot (a+b)^*) =$  todas las palabras con una o más  $b$ 's.

**Definición.** Usamos las siguientes **abreviaciones** de expresiones regulares:

$$\begin{aligned} R^+ &\equiv R \cdot R^* \\ R^k &\equiv R \cdot \overset{k}{\dots} \cdot R \\ R^? &\equiv R + \epsilon \\ \Sigma &\equiv a_1 + \dots + a_n \end{aligned}$$

para  $R \in \text{ExpRegs}$  y  $\Sigma = \{a_1, \dots, a_n\}$ .

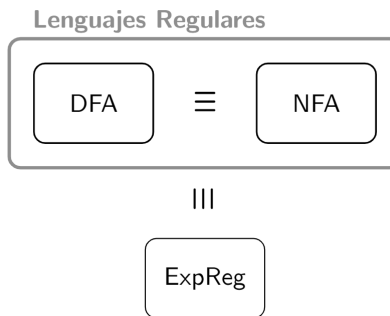
**Ejemplo 1.14**

Más lenguajes definidos por algunas ExpReg:

- ♦  $\mathcal{L}(\Sigma^* \cdot b \cdot \Sigma^*) =$  todas las palabras con una sola  $b$ .
- ♦  $\mathcal{L}(b^* \cdot (a \cdot b)^5) =$  todas las palabras con 5  $a$ 's.
- ♦  $\mathcal{L}(a^* \cdot (b + c)^?) =$  todas las palabras de  $a$ 's y terminadas en  $b$  o  $c$ .
- ♦  $\mathcal{L}((a \cdot b^+)^+) =$  todas las palabras que empiezan con  $a$  y donde cada  $a$  esta seguida de al menos una  $b$ .

**1.5. Autómatas con transiciones sin lectura**

Hasta ahora, hemos visto lo siguiente:



**Figura 2:** Mapa actual de nuestros modelos de computación

Podemos demostrar que  $\text{ExpReg} \subseteq \text{NFA}$ , pero para eso necesitamos un nuevo modelo.

**1.5.1.  $\epsilon$ -NFA**

Lo nuevo de este autómata:

1. tiene transiciones no deterministas y
2. tiene transiciones leyendo la palabra vacía  $\epsilon$ :

$$p \xrightarrow{\epsilon} q$$

La importancia de un  $\epsilon$ -NFA es que es un modelo **muy útil** para construir nuevos autómatas y **NO** agrega más poder de computación a los NFA.

**Definición.** Un autómata finito no-determinista con  $\epsilon$ -transiciones ( $\epsilon$ -NFA) es una tupla:

$$\mathcal{A} = (Q, \Sigma, \Delta, I, F)$$


- ♦  $Q$  es un conjunto finito de estados.
- ♦  $\Sigma$  es el alfabeto del input.
- ♦  $I \subseteq Q$  es un conjunto de estados iniciales.



- ♦  $F \subseteq Q$  es el conjunto de estados finales (o aceptación).
- ♦  $\Delta \subseteq Q \times (\Sigma \cup \{\epsilon\}) \times Q$  es la relación de transición.

### Ejemplo 1.15

Algunos ejemplos de  $\epsilon$ -NFA's:



Para  $\epsilon$ -NFA veremos una **forma alternativa** para definir las nociones de ejecución y aceptación.

**Ejecución.** Sea  $\mathcal{A} = (Q, \Sigma, \Delta, I, F)$  un  $\epsilon$ -NFA. Definimos:

- ♦ Un par  $(q, w) \in Q \times \Sigma^*$  es una **configuración** de  $\mathcal{A}$ .
- ♦ Una configuración  $(q, w)$  es **inicial** si  $q \in I$ .
- ♦ Una configuración  $(q, w)$  es **final** si  $q \in F$  y  $w = \epsilon$ .

*“Intuitivamente, una configuración  $(q, aw)$  representa que  $\mathcal{A}$  se encuentra en el estado  $q$  procesando la palabra  $aw$  y leyendo  $a$ ”.*

- ♦ Se define la relación  $\vdash_{\mathcal{A}} \subseteq (Q \times \Sigma^*) \times (Q \times \Sigma^*)$  de **siguiente-paso** entre configuraciones de  $\mathcal{A}$ :

$$(p, u) \vdash_{\mathcal{A}} (q, v)$$


si, y sólo si, existe  $(p, c, q) \in \Delta$  con  $c \in \Sigma \cup \{\epsilon\}$  tal que  $u = c \cdot v$ .

- ♦ Se define  $\vdash_{\mathcal{A}}^*$  como la clausura **refleja** y **transitiva** de  $\vdash_{\mathcal{A}}$ :

$$\begin{array}{ll} \text{para toda configuración } (q, w) : & (q, w) \vdash_{\mathcal{A}}^* (q, w) \\ \text{si } (p, u) \vdash_{\mathcal{A}} (p', w) \text{ y } (p', w) \vdash_{\mathcal{A}}^* (q, v) : & (p, u) \vdash_{\mathcal{A}}^* (q, v) \end{array}$$

Decimos que  $(p, u) \vdash_{\mathcal{A}}^* (q, v)$  si uno puede ir de  $(p, u)$  a  $(q, v)$  en **0 o más pasos**.

### Ejemplo 1.16



$$(1, baa) \vdash_{\mathcal{A}} (2, aa)$$

$$(2, aa) \vdash_{\mathcal{A}} (0, a) \vdash_{\mathcal{A}} (2, a) \vdash_{\mathcal{A}} (0, \epsilon)$$

$$(2, aa) \vdash_{\mathcal{A}}^* (0, \epsilon) \quad \text{y} \quad (1, baa) \vdash_{\mathcal{A}}^* (0, \epsilon)$$

**Aceptación.** Sea  $\mathcal{A} = (Q, \Sigma, \Delta, I, F)$  un  $\epsilon$ -NFA y  $w \in \Sigma^*$ . Decimos que  $\mathcal{A}$  **acepta**  $w$  si existe una configuración **inicial**  $(q_0, w)$  y una configuración **final**  $(q_f, \epsilon)$  tal que:

$$(q_0, w) \vdash_{\mathcal{A}}^* (q_f, \epsilon)$$

Además, el **lenguaje aceptado** por  $\mathcal{A}$  se define como:

$$\mathcal{L}(\mathcal{A}) = \{w \in \Sigma^* \mid \mathcal{A} \text{ acepta } w\}$$

**Nota.** Si  $\mathcal{A}$  no tiene  $\epsilon$ -transiciones o no-determinismo, esta es una forma **alternativa** para definir ejecución y aceptación para NFA y DFA.

### 1.5.2. NFA versus $\epsilon$ -NFA

Partimos enunciado el siguiente teorema:

#### Teorema 4

Para todo autómata finito no-determinista con  $\epsilon$ -transiciones  $\mathcal{A}$ , existe un autómata no-determinista  $\mathcal{A}'$  tal que:

$$\mathcal{L}(\mathcal{A}) = \mathcal{L}(\mathcal{A}')$$

En otras palabras,  $NFA \equiv \epsilon$ -NFA.

Para demostrar este teorema, mostraremos como construir un autómata no-determinista a partir de un  $\epsilon$ -NFA removiendo las  $\epsilon$ -transiciones.


**Construcción desde  $\epsilon$ -NFA a NFA.** Dado un  $\epsilon$ -NFA  $\mathcal{A} = (Q, \Sigma, \Delta, I, F)$  se define el NFA:

$$\mathcal{A}^{\epsilon'} = (Q, \Sigma, \Delta^{\epsilon'}, I, F^{\epsilon'})$$

♦ para todo  $p, q \in Q$ ,  $(p, a, q) \in \Delta^{\epsilon'}$  si, y sólo si, existe  $p' \in Q$  tal que:

- $(p, \epsilon) \vdash_{\mathcal{A}}^* (p', \epsilon)$  y
- $(p', a, q) \in \Delta$ .

♦  $F^{\epsilon'} = \{p \in Q \mid \exists q \in F. (p, \epsilon) \vdash_{\mathcal{A}}^* (q, \epsilon)\}$



Por definición, si  $(p, a, q) \in \Delta$ , entonces  $(p, a, q) \in \Delta^{\epsilon'}$  para todo  $a \in \Sigma$ .

#### Teorema 5

Dado un  $\epsilon$ -NFA  $\mathcal{A} = (Q, \Sigma, \Delta, I, F)$  se tiene que:

$$\mathcal{L}(\mathcal{A}) = \mathcal{L}(\mathcal{A}^{\epsilon'})$$

**Demostración teorema 5.** Demostrar el teorema anterior es equivalente a demostrar que para todo  $p \in Q$  y  $w \in \Sigma^*$ :

$$\exists q \in F. (p, w) \vdash_{\mathcal{A}}^* (q, \epsilon) \quad \text{si, y sólo si,} \quad \exists q' \in F^{\epsilon'}. (p, w) \vdash_{\mathcal{A}^{\epsilon'}}^* (q', \epsilon)$$

De aquí, podemos **concluir** que  $\mathcal{A}$  acepta  $w$  si, y sólo si,  $\mathcal{A}^{\epsilon'}$  acepta  $w$ .

Por **inducción** sobre el largo de  $w$ :

♦ **Caso base:** Para  $w = \epsilon$ :

( $\Rightarrow$ ) Sea  $q \in F$  tal que  $(p, \epsilon) \vdash_{\mathcal{A}}^* (q, \epsilon)$ . Por definición de  $F^{\epsilon}$ , se tiene que  $p \in F^{\epsilon}$ . Por lo tanto,  $(p, \epsilon) \vdash_{\mathcal{A}^{\epsilon}}^* (p, \epsilon)$ .

( $\Leftarrow$ ) Sea  $q' \in F^{\epsilon}$  tal que  $(p, \epsilon) \vdash_{\mathcal{A}^{\epsilon}}^* (q', \epsilon)$ . Como  $\mathcal{A}^{\epsilon}$  no tiene  $\epsilon$ -transiciones, entonces  $p = q'$  y  $p \in F^{\epsilon}$ . Por definición de  $F^{\epsilon}$ , existe  $q \in F$  tal que  $(p, \epsilon) \vdash_{\mathcal{A}}^* (q, \epsilon)$ .

♦ **Caso inductivo:** Sea  $w = a \cdot u$  y  $p \in Q$ :

( $\Leftarrow$ ) Sea  $q' \in F^{\epsilon}$  tal que  $(p, au) \vdash_{\mathcal{A}^{\epsilon}}^* (q', \epsilon)$ . Por definición de  $\vdash_{\mathcal{A}^{\epsilon}}^*$  existen  $p' \in Q$  tal que:

$$(p, au) \stackrel{(1)}{\vdash}_{\mathcal{A}^{\epsilon}}^* (p', u) \stackrel{(2)}{\vdash}_{\mathcal{A}^{\epsilon}}^* (q', \epsilon)$$

Por (1) sabemos que  $(p, au) \vdash_{\mathcal{A}}^* (p', u)$ . (3)

Como  $|u| < |au|$  y por (2), por **HI** existe  $q \in F$ :  $(p', u) \vdash_{\mathcal{A}}^* (q, \epsilon)$ . (4)

Juntando (3) y (4), tenemos que  $(p, au) \vdash_{\mathcal{A}}^* (q, \epsilon)$ .

( $\Rightarrow$ ) Sea  $q \in F$  tal que  $(p, au) \vdash_{\mathcal{A}}^* (q, \epsilon)$ . Por definición de  $\vdash_{\mathcal{A}}^*$  existen  $p', p'' \in Q$  tal que:

$$(p, au) \stackrel{(1)}{\vdash}_{\mathcal{A}}^* (p', au) \stackrel{(2)}{\vdash}_{\mathcal{A}}^* (p'', u) \stackrel{(3)}{\vdash}_{\mathcal{A}}^* (q, \epsilon)$$

Por (1) tenemos que  $(p, \epsilon) \vdash_{\mathcal{A}}^* (p', \epsilon)$ . (4)

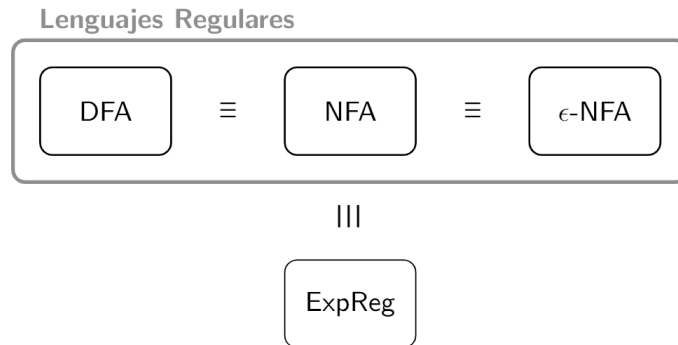
Por (2) tenemos que  $(p', a, p'') \in \Delta$ . (5)

Por (4) y (5), sabemos que  $(p, a, p'') \in \Delta^{\epsilon}$  y  $(p, a \cdot u) \vdash_{\mathcal{A}^{\epsilon}}^* (p'', u)$ . (6)

Como  $|u| < |au|$  y (3), **por HI** existe  $q' \in F^{\epsilon}$ :  $(p'', u) \vdash_{\mathcal{A}^{\epsilon}}^* (q', \epsilon)$ . (7)

Juntando (6) y (7), tenemos que  $(p, au) \vdash_{\mathcal{A}^{\epsilon}}^* (q', \epsilon)$ . ■

Con el teorema 5 demostrado, nuestro mapa de modelos se ve así:



**Figura 3:** Mapa actual de nuestros modelos de computación

En la siguiente sección mostraremos que todos definen el mismo conjunto de lenguajes.

## 1.6. Teorema de Kleene

### 1.6.1. Desde Expresiones a Autómatas

Veremos a continuación que toda ExpReg se puede transformar en un autómatas.



**Construcción inductiva.** Para cada  $R \in \text{ExpReg}$ , construimos un  $\epsilon$ -NFA  $\mathcal{A}_R$ :

$$\mathcal{A}_R = (Q, \Sigma, \Delta, \{q_0\}, \{q_f\})$$


tal que  $\mathcal{L}(R) = \mathcal{L}(\mathcal{A}_R)$ .

**Casos bases.** Vemos primero los casos base de la construcción inductiva:

1. si  $R = a$ ,  
para alguna letra  $a \in \Sigma$ :
2. si  $R = \epsilon$ :
3. si  $R = \emptyset$ :



4. si  $R = (R_1 + R_2)$ , donde  $R_1$  y  $R_2$  son expresiones regulares:



Hacemos la construcción inductiva de  $R = (R_1 + R_2)$  por **inducción**. Sea  $\mathcal{A}_{R_1}$  y  $\mathcal{A}_{R_2}$  los  $\epsilon$ -NFA para  $R_1$  y  $R_2$ , respectivamente, tal que:

$$\diamond \mathcal{A}_{R_1} = (Q_1, \Sigma, \Delta_1, \{q_0^1\}, \{q_f^1\})$$

$$\diamond \mathcal{A}_{R_2} = (Q_2, \Sigma, \Delta_2, \{q_0^2\}, \{q_f^2\})$$

Definimos el  $\epsilon$ -NFA  $\mathcal{A}_{R_1+R_2} = (Q, \Sigma, \Delta, \{q_0\}, \{q_f\})$  tal que:


$$\diamond Q = Q_1 \uplus Q_2 \uplus \{q_0, q_f\}$$

$$\diamond \Delta = \Delta_1 \uplus \Delta_2 \uplus \left\{ (q_0, \epsilon, q_0^1), (q_0, \epsilon, q_0^2), (q_f^1, \epsilon, q_f), (q_f^2, \epsilon, q_f) \right\}$$

**Proposición.** Si  $R = (R_1 + R_2)$ , entonces  $\mathcal{L}(R_1 + R_2) = \mathcal{L}(\mathcal{A}_{R_1+R_2})$ .

La demostración de esta proposición queda como ejercicio propuesto para el lector.

5. si  $R = (R_1 \cdot R_2)$ , donde  $R_1$  y  $R_2$  son expresiones regulares:



Hacemos la construcción inductiva de  $R = (R_1 \cdot R_2)$  por **inducción**. Sea  $\mathcal{A}_{R_1}$  y  $\mathcal{A}_{R_2}$  los  $\epsilon$ -NFA para  $R_1$  y  $R_2$ , respectivamente, tal que:

$$\diamond \mathcal{A}_{R_1} = (Q_1, \Sigma, \Delta_1, \{q_0^1\}, \{q_f^1\})$$

$$\diamond \mathcal{A}_{R_2} = (Q_2, \Sigma, \Delta_2, \{q_0^2\}, \{q_f^2\})$$

Definimos el  $\epsilon$ -NFA  $\mathcal{A}_{R_1 \cdot R_2} = (Q, \Sigma, \Delta, \{q_0^1\}, \{q_f^2\})$  tal que:


$$\diamond Q = Q_1 \uplus Q_2$$

$$\diamond \Delta = \Delta_1 \uplus \Delta_2 \uplus \left\{ \left( q_f^1, \epsilon, q_0^2 \right) \right\}$$

**Proposición.** Si  $R = (R_1 \cdot R_2)$ , entonces  $\mathcal{L}(R_1 \cdot R_2) = \mathcal{L}(\mathcal{A}_{R_1 \cdot R_2})$ .

La demostración de esta proposición queda como ejercicio propuesto para el lector.

6. si  $R = (R_1^*)$ , donde  $R_1$  es una expresión regular:



Hacemos la construcción inductiva de  $R = (R_1^*)$  por **inducción**. Sea  $\mathcal{A}_{R_1}$  el  $\epsilon$ -NFA para  $R_1$ , tal que:

$$\diamond \mathcal{A}_{R_1} = (Q_1, \Sigma, \Delta_1, \{q_0^1\}, \{q_f^1\})$$

Definimos el  $\epsilon$ -NFA  $\mathcal{A}_{(R_1^*)} = (Q, \Sigma, \Delta, \{q_0\}, \{q_0\})$  tal que:

$$\diamond Q = Q_1 \uplus \{q_0\}$$

$$\diamond \Delta = \Delta_1 \uplus \left\{ \left( q_0, \epsilon, q_0^1 \right), \left( q_f^1, \epsilon, q_0 \right) \right\}$$

**Proposición.** Si  $R = (R_1^*)$ , entonces  $\mathcal{L}(R_1^*) = \mathcal{L}(\mathcal{A}_{(R_1^*)})$ .

La demostración de esta proposición queda como ejercicio propuesto para el lector.

#### Teorema 6

Para todo  $R \in \text{ExpReg}$ , existe un  $\epsilon$ -NFA  $\mathcal{A}_R$  tal que:

$$\mathcal{L}(R) = \mathcal{L}(\mathcal{A}_R)$$

En otras palabras,  $\text{ExpReg} \subseteq \epsilon\text{-NFA}$ .

#### 1.6.2. Desde Autómatas a Expresiones

Dado un autómata finito no-determinista (que, sin pérdida de generalidad, tiene un estado inicial):

$$\mathcal{A} = (Q, \Sigma, \Delta, q_0, F)$$

Para  $X \subseteq Q$  y  $p, q \in Q$ , considerar el conjunto:

$$\alpha_{p,q}^X \subseteq \Sigma^*$$

tal que  $w = a_1 \dots a_n \in \alpha_{p,q}^X$  si, y sólo si, existe una **ejecución**:

$$\rho : p_0 \xrightarrow{a_1} p_1 \xrightarrow{a_2} \dots \xrightarrow{a_n} p_n$$

1.  $(p_i, a_{i+1}, p_{i+1}) \in \Delta$  para todo  $i \in [0, n-1]$ ,
2.  $p_0 = p$ ,
3.  $p_n = q$ , y
4.  $p_i \in X$  para todo  $i \in [1, n-1]$ .

“Intuitivamente,  $\alpha_{p,q}^X$  es el conjunto de todas las palabras  $w$  tal que existe un **camino** (i.e. ejecución) desde  $p$  a  $q$  etiquetado por  $w$  y **todos los estados** en este camino están en  $X$ , con la posible excepción de  $p$  y  $q$ ”.

¿Cómo definimos  $\mathcal{L}(\mathcal{A})$  en términos de  $\alpha_{p,q}^X$ ? Establecemos el siguiente lema:

$$\mathcal{L}(\mathcal{A}) = \bigcup_{q \in F} \alpha_{q_0, p}^Q$$

**Estrategia.** Conocida como el algoritmo de McNaughton-Yamada:

1. Para cada  $\alpha_{p,q}^X$ , definir **inductivamente** una expresión regular  $R_{p,q}^X$ :

$$\mathcal{L}(R_{p,q}^X) = \alpha_{p,q}^X$$

2. Para  $F = \{p_1, \dots, p_k\}$  definir la **expresión regular**:

$$R_{\mathcal{A}} = R_{q_0, p_1}^Q + R_{q_0, p_2}^Q + \dots + R_{q_0, p_k}^Q$$

3. Demostrar que:

$$\mathcal{L}(\mathcal{A}) = \mathcal{L}(R_{\mathcal{A}})$$

**Definición inductiva de  $R_{p,q}^X$ .** Tenemos que:

♦ **Caso base:**  $X = \emptyset$

Sea  $a_1, \dots, a_k \in \Sigma$  todas las letras tal que:

$$(p, a_i, q) \in \Delta$$

- Si  $p \neq q$ , entonces:

$$R_{p,q}^{\emptyset} \stackrel{\text{def}}{=} \begin{cases} a_1 + \dots + a_k & \text{si } k \geq 1 \\ \emptyset & \text{si } k = 0 \end{cases}$$

- Si  $p = q$ , entonces:

$$R_{p,q}^{\emptyset} \stackrel{\text{def}}{=} \begin{cases} a_1 + \dots + a_k + \epsilon & \text{si } k \geq 1 \\ \epsilon & \text{si } k = 0 \end{cases}$$

♦ **Caso general:**  $X \neq \emptyset$

Por **inducción**, suponemos que para todo  $r, s \in Q$  y para todo  $Y \subset X$ ,  $R_{r,s}^Y$  es una expresión regular tal que:

$$\mathcal{L}(R_{r,s}^Y) = \alpha_{r,s}^Y$$

Demostramos la construcción para  $R_{p,q}^X$  con  $p, q \in Q$ . Sea  $r \in X$  cualquiera:

$$R_{p,q}^X \stackrel{\text{def}}{=} R_{p,q}^{X-\{r\}} + R_{p,r}^{X-\{r\}} \cdot \left( R_{r,r}^{X-\{r\}} \right)^* \cdot R_{r,q}^{X-\{r\}}$$


**Proposición.** Para todo  $X \subseteq Q$  y  $p, q \in Q$ :

$$\mathcal{L}(R_{p,q}^X) = \alpha_{p,q}^X$$

**Corolario.**  $\mathcal{L}(\mathcal{A}) = \mathcal{L}(R_{\mathcal{A}})$

**Ejemplo 1.17: Algoritmo MNY**

Considere el autómata:



$R^{\emptyset}$	1	2
1	$a^?$	$b$
2	$a$	$\epsilon$

$R^{\{1\}}$	1	2
1	$a^? + a^? \cdot (a^?)^* \cdot a^?$	$b + a^? \cdot (a^?)^* \cdot b$
2	$a + a \cdot (a^?)^* \cdot a^?$	$\epsilon + a \cdot (a^?)^* \cdot b$

 $\equiv$ 

$R^{\{1\}}$	1	2
1	$a^*$	$a^*b$
2	$a^+$	$\epsilon + a^+b$

$R^{\{1,2\}}$	1	2
1	$a^* + a^*b(\epsilon + a^+b)^* a^+$	$a^*b + a^*b(\epsilon + a^+b)^* (\epsilon + a^+b)$
2	$a^+ + (\epsilon + a^+b)(\epsilon + a^+b)^* a^+$	$(\epsilon + a^+b) + (\epsilon + a^+b)(\epsilon + a^+b)^* (\epsilon + a^+b)$

 $\equiv$ 

$R^{\{1,2\}}$	1	2
1	$a^* (ba^+)^*$	$(a^*b)(a^+b)^*$
2	$(a^+b)^* a^+$	$(a^+b)^*$

## 2. Propiedades de lenguajes regulares

### 2.1. Lema de bombeo

Supongamos que deseamos aceptar el siguiente lenguaje:

$$L = \{a^i b^i \mid i \geq 0\} = \{\epsilon, ab, aabb, aaabbb, aaaaabbbb, \dots\}$$

con un **autómata finito determinista**. ¿Es posible? La respuesta es que no, ya que nuestros autómatas no tienen la capacidad de “contar”. Por ende,  $L$  sería un lenguaje NO regular ya que no podría ser definido por un autómata.

**Enunciado.** Sea  $L \subseteq \Sigma^*$ . Si  $L$  es **regular**, entonces:

(LB) existe un  $N > 0$  tal que  
 para toda palabra  $x \cdot y \cdot z \in L$  con  $|y| \geq N$   
 existen palabras  $u \cdot v \cdot w = y$  con  $v \neq \epsilon$  tal que  
 para todo  $i \geq 0$ ,  $x \cdot u \cdot v^i \cdot w \cdot z \in L$ .

El contrapositivo del lema de bombeo nos servirá para demostrar que un lenguaje  $L$  NO es regular.

Sea  $L \subseteq \Sigma^*$ . Si:

(¬LB) para todo  $N > 0$   
 existe una palabra  $x \cdot y \cdot z \in L$  con  $|y| \geq N$  tal que  
 para todo  $u \cdot v \cdot w = y$  con  $v \neq \epsilon$   
 existe un  $i \geq 0$ ,  $x \cdot u \cdot v^i \cdot w \cdot z \notin L$ .  
 entonces  $L$  NO es regular.



“ $L$  NO es regular”



“ $L$  es regular”

**El escoge un  $N > 0$**

**Uno escoge  $x \cdot y \cdot z \in L$  con  $|y| \geq N$**

**El escoge  $u \cdot v \cdot w = y$  con  $v \neq \epsilon$**

**Uno escoge  $i \geq 0$**

**Uno gana si  $xuv^i wz \notin L$**

**El gana si  $xuv^i wz \in L$**

**LB versión juego.** “Dado un lenguaje  $L \subseteq \Sigma^*$ , si **UNO** tiene una estrategia ganadora en el juego (¬LB) para toda estrategia posible del demonio, entonces  $L$  **NO es regular**”. Con **estrategia**, nos referimos a todas las movidas posibles que podría ejecutar el **demonio** (considerar todos los casos posibles de sus elecciones).



## Ejemplo 2.1

Considere el lenguaje  $L = \{a^i b^i \mid i \geq 0\}$ :



" $a^n b^n$  NO es regular"



" $a^n b^n$  es regular"

Escojo  $N > 0$

Yo escojo  $\underbrace{a^N}_x \cdot \underbrace{b^N}_y \cdot \underbrace{\epsilon}_z \in L$

Entonces escojo  $\underbrace{b^n}_u \cdot \underbrace{b^m}_v \cdot \underbrace{b^l}_w = \underbrace{b^N}_y$  con  $m > 0$

Yo escojo  $i = 2$

Ganamos el juego ya que con  $i = 2$  estaremos bombeando más  $b$ -letras y entonces la palabra no tendrá la misma cantidad de  $a$ -letras que de  $b$ -letras ( $i \neq j$ ), por ende,  $L$  NO es regular.

## Ejemplo 2.2

Considere el lenguaje  $L = \{a^n b^m \mid n \geq m\}$ :



" $a^n b^m$  NO es regular"



" $a^n b^m$  es regular"

Escojo  $N > 0$

Yo escojo  $\underbrace{a^N}_x \cdot \underbrace{b^N}_y \cdot \underbrace{\epsilon}_z \in L$

Entonces escojo  $\underbrace{b^j}_u \cdot \underbrace{b^k}_v \cdot \underbrace{b^l}_w = \underbrace{b^N}_y$  con  $k > 0$

Yo escojo  $i = 2$

Ganamos el juego ya que, nuevamente, con  $i = 2$ , estaremos bombeando más  $b$ -letras y entonces la palabra puede tener más  $b$ -letras que  $a$ -letras ( $n < m$ ), y así  $L$  NO es regular.

**Ejemplo 2.3**

Considere el lenguaje  $L = \{w \cdot w \mid w \in \{a, b\}^*\}$



“ $L$  NO es regular”



“ $L$  es regular”

**Escojo  $N > 0$**

**Yo escojo**  $\underbrace{a^N}_x \underbrace{b}_y \cdot \underbrace{a^N}_y \cdot \underbrace{b}_z \in L$

**Entonces escojo**  $\underbrace{a^i}_u \cdot \underbrace{a^k}_v \cdot \underbrace{a^l}_w = \underbrace{a^N}_y$  con  $k > 0$

**Yo escojo  $i = 0$**

Ganamos el juego ya que con la elección de  $i = 0$  estamos haciendo que una de las mitades de la palabra sea distinta a su otra mitad, por ende,  $L$  NO es regular.

**Ejemplo 2.4**

Considere el lenguaje  $L = \{a^{2^n} \mid n > 0\}$



“ $a^{2^n}$  NO es regular”



“ $a^{2^n}$  es regular”

**Escojo  $N > 0$**

**Yo escojo**  $\underbrace{a^{2^N - N}}_x \cdot \underbrace{a^N}_y \cdot \underbrace{\epsilon}_z \in L$  con  $N < 2^n$


**Entonces escojo**  $\underbrace{a^i}_u \cdot \underbrace{a^k}_v \cdot \underbrace{a^l}_w = \underbrace{a^N}_y$  con  $k > 0$

**Yo escojo  $i = 2$**

Ganamos el juego ya que con la elección de  $i = 2$ , tenemos que en la elección de  $y$  tendremos una mayor cantidad de  $a$ -letras bombeadas y se romperá el equilibrio  $2^N - N + N$ , por ende,  $L$  NO es regular.

## 2.2. Minimización de autómatas

¿Cómo minimizamos un autómata finito?



**Figura 4:** Idea de minimización

1. Eliminar estados inaccesibles.


♦ Fácil de realizar y no cambia el lenguaje del autómata finito.

2. Colapsar estados “equivalentes”.

♦ ¿Cómo sabemos cuáles estados colapsar y cuáles no?

### Ejemplo 2.5


Considere el siguiente autómata:



Podemos:


♦ Colapsar estados 1 y 2.

♦ Colapsar estados 3 y 4.




**Ejemplo 2.6**

Considere el siguiente autómata:



Podemos:

- ♦ Colapsar estados 1 y 2.
- ♦ Colapsar estados 3, 4 y 5.

**2.2.1. Colapsar estados**

**Definición.** Sea  $\mathcal{A} = (Q, \Sigma, \delta, q_0, F)$  un DFA.

Se define la **función de transición extendida**  $\hat{\delta} : Q \times \Sigma^* \rightarrow Q$  inductivamente como:

$$\begin{aligned} \hat{\delta}(q, \epsilon) &\stackrel{\text{def}}{=} q \\ \hat{\delta}(q, w \cdot a) &\stackrel{\text{def}}{=} \delta(\hat{\delta}(q, w), a) \end{aligned}$$

**Definición.** Decimos que  $p$  y  $q$  son **indistingibles** ( $p \approx_{\mathcal{A}} q$ ) si:

$$p \approx_{\mathcal{A}} q \quad \text{ssi} \quad (\hat{\delta}(p, w) \in F \Leftrightarrow \hat{\delta}(q, w) \in F), \text{ para todo } w \in \Sigma^*.$$

Decimos que  $p$  y  $q$  son **distingibles** si NO son indistingibles ( $p \not\approx_{\mathcal{A}} q$ ).

**Recordatorio relaciones de equivalencia.** Una relación  $\approx_R$  sobre un conjunto  $X$  se dice de **equivalencia** si es:

- ♦ **Refleja:**  $\forall p \in X. p \approx_R p$
- ♦ **Simétrica:**  $\forall p, q \in X. \text{ si } p \approx_R q \text{ entonces } q \approx_R p.$
- ♦ **Transitiva:**  $\forall p, q, r \in X. \text{ si } p \approx_R q \text{ y } q \approx_R r, \text{ entonces } p \approx_R r.$

Para un elemento  $p \in X$  se define su **clase de equivalencia** según  $\approx_R$  como:

$$[p]_{\approx_R} = \{q \mid q \approx_R p\}$$

Una función  $f : X \rightarrow X$  se dice **bien definida** sobre  $\approx_R$  si:

$$p \approx_R q \text{ entonces } f(p) \approx_R f(q)$$

**Propiedades de  $\approx_A$ .** Tenemos que:

♦  $\approx_A$  es una **relación de equivalencia**, es decir, es refleja, simétrica y transitiva.

♦ Cada estado  $p \in Q$  esta en exactamente una clase de equivalencia:

$$[p]_{\approx_A} = \{q \mid q \approx_A p\}$$

♦ Para todo  $a \in \Sigma$  la función  $\delta(\cdot, a) : Q \rightarrow Q$  esta **bien definida** sobre  $\approx_A$ :

$$p \approx_A q \text{ entonces } \delta(p, a) \approx_A \delta(q, a)$$

**El autómata cuociente.** Para un DFA  $\mathcal{A} = (Q, \Sigma, \delta, q_0, F)$  se define el DFA:

$$\mathcal{A}/\approx = (Q_{\approx}, \Sigma, \delta_{\approx}, q_{\approx}, F_{\approx})$$

♦  $Q_{\approx} = \{[p]_{\approx_A} \mid p \in Q\}$

♦  $\delta_{\approx}([p]_{\approx_A}, a) = [\delta(p, a)]_{\approx_A}$

♦  $q_{\approx} = [q_0]_{\approx_A}$

♦  $F_{\approx} = \{[p]_{\approx_A} \mid p \in F\}$

### Teorema 7

Para todo autómata finito determinista  $\mathcal{A}$  se cumple que:

$$\mathcal{L}(\mathcal{A}) = \mathcal{L}(\mathcal{A}/\approx)$$


**Demostración.** PENDIENTE. Pero se invita al lector a hacerla <3.

### 2.2.2. Algoritmo de minimización

El objetivo es buscar los pares de estados que son **distingibles**:

1. Construya una tabla con los pares  $\{p, q\}$  inicialmente sin marcar.
2. Marque  $\{p, q\}$  si  $p \in F$  y  $q \notin F$  o viceversa.
3. Repita este paso hasta que no hayan más cambios:
  - ♦ Si  $\{p, q\}$  no están marcados y  $\{\delta(p, a), \delta(q, a)\}$  estan marcados para algún  $a \in \Sigma$ , entonces marque  $\{p, q\}$ .
4. Al terminar,  $p \not\approx_A q$  si, y sólo si, la entrada  $\{p, q\}$  está marcada.

Veamos como funciona el algoritmo. Considere el siguiente autómata y una tabla que relacione todos los pares de estados:



1. Construya una tabla con los pares  $\{p, q\}$  inicialmente sin marcar.
2. Marque  $\{p, q\}$  si  $p \in F$  y  $q \notin F$  o viceversa.

	1	2	3	4	5	6
1						
2						
3						
4						
5						
6						

	1	2	3	4	5	6
1		✓		✓	✓	✓
2			✓			
3				✓	✓	✓
4						
5						
6						

3. Repita este paso hasta que no hayan más cambios:

- ♦ Si  $\{p, q\}$  no están marcados y  $\{\delta(p, a), \delta(q, a)\}$  están marcados para algún  $a \in \Sigma$ , entonces marque  $\{p, q\}$ .

	1	2	3	4	5	6
1		✓		✓	✓	✓
2			✓	$\begin{smallmatrix} a \\ (3,6) \end{smallmatrix}$	$\begin{smallmatrix} a \\ (3,2) \end{smallmatrix}$	$\begin{smallmatrix} a \\ (3,6) \end{smallmatrix}$
3				✓	✓	✓
4						
5						
6						

	1	2	3	4	5	6
1		✓		✓	✓	✓
2			✓	✓	✓	✓
3				✓	✓	✓
4						
5						
6						

	1	2	3	4	5	6
1		✓		✓	✓	✓
2			✓	✓	✓	✓
3				✓	✓	✓
4					$\begin{smallmatrix} a \\ (6,2) \end{smallmatrix}$	
5						$\begin{smallmatrix} a \\ (2,6) \end{smallmatrix}$
6						

	1	2	3	4	5	6
1		✓		✓	✓	✓
2			✓	✓	✓	✓
3				✓	✓	✓
4					✓	
5						✓
6						

	1	2	3	4	5	6
1		✓		✓	✓	✓
2			✓	✓	✓	✓
3				✓	✓	✓
4					✓	$\begin{smallmatrix} b \\ (5,6) \end{smallmatrix}$
5						✓
6						

	1	2	3	4	5	6
1		✓		✓	✓	✓
2			✓	✓	✓	✓
3				✓	✓	✓
4					✓	✓
5						✓
6						

4. Al terminar,  $p \not\sim_{\mathcal{A}}$  si, y sólo si, la entrada  $\{p, q\}$  está marcada.

Así, vemos que los pares indistinguibles son todas las entradas **NO** marcadas.

### 2.3. Teorema de Myhill-Nerode

La sección anterior deja muchas incógnitas:

1. ¿Cómo sabemos si el autómata del algoritmo es un **mínimo**?
2. Dado  $L$ , ¿existe un **único** autómata mínimo?
3. Dado un  $\mathcal{A}$ , ¿es posible **construir** un autómata mínimo equivalente?

En esta sección, demostraremos que:

- ♦ El autómata con el mínimo de estados es **único**.
- ♦ El algoritmo de minimización **siempre** construye el autómata mínimo.

**Estrategia.** Para demostrar lo dicho anteriormente, seguimos los siguientes pasos:

1. Desde un DFA  $\mathcal{A}$ , definiremos una relación de equivalencia  $(RE) \equiv_{\mathcal{A}}$  entre palabras en  $\Sigma^*$ .
2. Desde una  $RE \equiv$  entre palabras, construiremos un DFA  $\mathcal{A}_{\equiv}$ .
3. A partir de un lenguaje  $L$ , definiremos una  $RE \equiv_L$ .
4.  $\mathcal{A}_{\equiv_L}$  define el autómata con la **menor cantidad de estados**.
5.  $\mathcal{A}_{\equiv_L}$  es equivalente al resultado de nuestro **algoritmo de minimización**.

#### 2.3.1. Relaciones de Myhill-Nerode

Sea  $L \subseteq \Sigma^*$  cualquier lenguaje.

**Definición.** Una relación de equivalencia  $\equiv$  en  $\Sigma^*$  es de **Myhill-Nerode** para  $L$  si:

1.  $\equiv$  es una **congruencia por la derecha**.
2.  $\equiv$  **refina**  $L$ .
3. El número de clases de equivalencia de  $\equiv$  es **finita**.

A partir de una relación  $\equiv$  de Myhill-Nerode podemos construir un DFA  $\mathcal{A}_{\equiv}$ .

$$\begin{array}{lcl} \mathcal{A} & \Rightarrow & \equiv_{\mathcal{A}} \\ \equiv & \Rightarrow & \mathcal{A}_{\equiv} \end{array}$$

**Construcción del DFA  $\mathcal{A}_{\equiv}$ .** Dada una relación de Myhill-Nerode  $\equiv$  para  $L \subseteq \Sigma^*$ , definimos el autómata:

$$\mathcal{A}_{\equiv} = (Q_{\equiv}, \Sigma, \delta_{\equiv}, q_{\equiv}, F_{\equiv})$$

- ♦  $Q_{\equiv} = \{[w]_{\equiv} \mid w \in \Sigma^*\}$
- ♦  $q_{\equiv} = [\epsilon]_{\equiv}$
- ♦  $F_{\equiv} = \{[w]_{\equiv} \mid w \in L\}$
- ♦  $\delta_{\equiv}([w]_{\equiv}, a) = [wa]_{\equiv}$

**Teorema 8**

Cada cualquier  $L \subseteq \Sigma^*$ , tenemos que

$$\mathcal{L}(\mathcal{A}_{\equiv}) = L$$

Podemos establecer que  $\mathcal{A} \Rightarrow \equiv_{\mathcal{A}}$  y  $\equiv \Rightarrow \mathcal{A}_{\equiv}$  son procesos inversos, conclusión que se ilustra en el siguiente teorema.

**Teorema 9**

1. Si  $\mathcal{A}$  es un DFA que acepta  $L$  y si construimos:

$$\mathcal{A} \Rightarrow \equiv_{\mathcal{A}} \Rightarrow \mathcal{A}_{\equiv_{\mathcal{A}}}$$

entonces  $\mathcal{A}$  es **isomorfo** (“equivalente”) a  $\mathcal{A}_{\equiv_{\mathcal{A}}}$ .

2. Si  $\equiv$  es una relación de Myhill-Nerode para  $L$  y si construimos:

$$\equiv \Rightarrow \mathcal{A}_{\equiv} \Rightarrow \equiv_{\mathcal{A}_{\equiv}}$$

entonces la relación  $\equiv$  es **equivalente** a  $\equiv_{\mathcal{A}_{\equiv}}$ .

La demostración de ambos teoremas queda propuesto como ejercicio al lector.

**2.3.2. Camino al teorema**

Antes de enunciar el Teorema de Myhill-Nerode, debemos aún mencionar algunas definiciones.

**Definición.** Dado un lenguaje  $L \subseteq \Sigma^*$ , se define la relación de equivalencia  $\equiv_L$  como:

$$u \equiv_L v \quad \text{ssi} \quad (u \cdot w \in L \Leftrightarrow v \cdot w \in L) \quad \forall w \in \Sigma^*$$

**Ejemplo 2.7**

Sea  $L = (ab)^*$ . Algunas clases de equivalencia para  $L$  son:

- ♦  $[\epsilon]_{\equiv_L} = \{\epsilon, ab, abab, ababab, \dots\}$ .
- ♦  $[a]_{\equiv_L} = \{a, aba, ababa, abababa, \dots\}$ .
- ♦  $[b]_{\equiv_L} = \{b, bb, ba, abb, \dots\}$

**Propiedades.**  $\equiv_L$  se caracteriza por:

1. Ser una **congruencia por la derecha**:

$$u \equiv_L v \text{ entonces } u \cdot w \equiv_L v \cdot w \quad \forall w \in \Sigma^*$$

2. Refinar a  $L$ :

$$u \equiv_L v \text{ entonces } (u \in L \Leftrightarrow v \in L)$$

3. Si  $\equiv$  es una congruencia por la derecha y refina  $L$ , entonces  $\equiv$  **refina** a  $\equiv_L$ :

$$u \equiv v \text{ entonces } u \equiv_L v$$



Con todo lo anterior, estamos en condiciones de enunciar el teorema.

### Teorema 10

Sea  $L \subseteq \Sigma^*$ . Las siguientes propiedades son equivalentes:

1.  $L$  es **regular**.
2. Existe una **relación de Myhill-Nerode** para  $L$ .
3. La relación  $\equiv_L$  tiene una cantidad **finita** de clases de equivalencia.

**Demostración teorema 10.** Del punto 1 al 2, tenemos que si  $L$  es regular, entonces:

♦ existe un autómata finito  $\mathcal{A}$  tal que  $L = \mathcal{L}(\mathcal{A})$ .

♦  $\equiv_{\mathcal{A}}$  es una relación de Myhill-Nerode para  $L$ .

Del punto 2 al 3, sea  $\equiv$  una relación de Myhill-Nerode para  $L$ , entonces:

♦  $\equiv$  tiene una cantidad finita de clases de equivalencia.

♦  $\equiv_L$  tiene una cantidad finita de clases de equivalencia.

Del punto 3 al 1, si  $\equiv_L$  tiene una cantidad **finita** de clases de equivalencia, entonces:

♦  $\equiv_L$  es una relación de Myhill-Nerode para  $L$ .

♦  $\mathcal{A}_{\equiv_L}$  es un autómata finito para  $L$ . ■

**Conclusiones del teorema.** Tenemos que:

1.  $\equiv_L \Rightarrow \mathcal{A}_{\equiv_L}$  produce el autómata con la menor cantidad de estados.
2. Todo autómata  $\mathcal{A}$  tal que  $\equiv_{\mathcal{A}} = \equiv_L$  son **isomorfos** (“equivalentes”).
3. El **algoritmo de minimización** produce un autómata isomorfo  $\mathcal{A}_{\equiv_L}$ .

**Demostración punto 3.** Sea  $\mathcal{A} = (Q, \Sigma, \delta, q_0, F)$  un autómata que acepta  $L$  ya **minimizado**:

$$\begin{aligned}
 u \equiv_L v &\Leftrightarrow (u \cdot w \in L \Leftrightarrow v \cdot w \in L) \quad \forall w \in \Sigma^* \\
 &\Leftrightarrow \left( \hat{\delta}(q_0, u \cdot w) \in F \Leftrightarrow \hat{\delta}(q_0, v \cdot w) \in F \right) \quad \forall w \in \Sigma^* \\
 &\Leftrightarrow \left( \hat{\delta}(\hat{\delta}(q_0, u), w) \in F \Leftrightarrow \hat{\delta}(\hat{\delta}(q_0, v), w) \in F \right) \quad \forall w \in \Sigma^* \\
 &\Leftrightarrow \hat{\delta}(q_0, u) \approx_{\mathcal{A}} \hat{\delta}(q_0, v) \\
 &\Leftrightarrow \hat{\delta}(q_0, u) = \hat{\delta}(q_0, v) \\
 &\Leftrightarrow u \equiv_{\mathcal{A}} v
 \end{aligned}$$

■

## 2.4. Autómatas en dos direcciones

### 3. Algoritmos para lenguajes regulares

- 3.1. Evaluación de expresiones regulares
- 3.2. Transductores
- 3.3. Análisis léxico
- 3.4. Algoritmo de Knuth-Morris-Prat

## 4. Lenguajes libres de contexto

### 4.1. Gramáticas libres de contexto

### 4.2. Simplificación de gramáticas

### 4.3. Forma normal de Chomsky

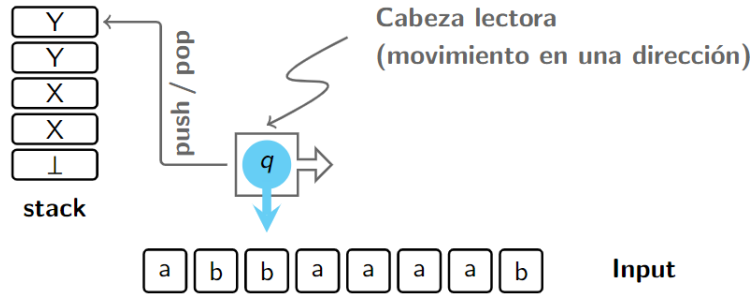
### 4.4. Lema de bombeo para lenguajes libres de contexto

### 4.5. Algoritmo CKY

## 5. Algoritmos para lenguajes libres de contexto

### 5.1. Autómatas apiladores

#### 5.1.1. Versión normal



**Figura 5:** Idea de un autómata apilador

**Definición.** Un autómata apilador (*PushDown Automata*, PDA) es una estructura:

$$\mathcal{P} = (Q, \Sigma, \Gamma, \Delta, q_0, \perp, F)$$

- ♦  $Q$  es un conjunto finito de **estados**.
- ♦  $\Sigma$  es el alfabeto del **input**.
- ♦  $q_0 \in Q$  es el estado **inicial**.
- ♦  $F$  es el conjunto de estados **finales**.
- ♦  $\Gamma$  es el alfabeto de **stack**.
- ♦  $\perp \in \Gamma$  es el símbolo **inicial del stack** (fondo).
- ♦  $\Delta \subseteq (Q \times (\Sigma \cup \{\epsilon\}) \times \Gamma) \times (Q \times \Gamma^*)$  es una relación finita de transición.

Intuitivamente, la transición:

$$\left( (p, a, A), (q, B_1 B_2 \cdots B_k) \right) \in \Delta$$

si el autómata apilador está:

- ♦ en el estado  $p$ , leyendo  $a$ , y en el tope del stack hay una  $A$ ,
- entonces:
- ♦ cambia al estado  $q$ , y modifico el tope  $A$  por  $B_1 B_2 \cdots B_k$ .

Intuitivamente, la transición **en vacío**:

$$\left( (p, \epsilon, A), (q, B_1 B_2 \cdots B_k) \right) \in \Delta$$

si el autómata apilador está:

- ♦ en el estado  $p$ , *sin lectura de una letra*, y en el tope del stack hay una  $A$ ,
- entonces:
- ♦ cambia al estado  $q$ , y modifico el tope  $A$  por  $B_1 B_2 \cdots B_k$ .

**Ejemplo 5.1**

$$\mathcal{P} = (Q, \Sigma, \Gamma, \Delta, q_0, \perp, \{q_f\})$$

♦  $Q = \{q_0, q_1, q_f\}$ ,  $\Sigma = \{a, b\}$ ,  $\Gamma = \{A, \perp\}$  y  $\Delta$ :


$$(q_0, a, \perp, q_0, A \perp) \quad q_0 \perp \xrightarrow{a} q_0 A \perp$$

$$(q_0, a, A, q_0, AA) \quad q_0 A \xrightarrow{a} q_0 AA$$

$$(q_0, b, A, q_1, \epsilon) \quad q_0 A \xrightarrow{b} q_1$$

$$(q_1, b, A, q_1, \epsilon) \quad q_1 A \xrightarrow{b} q_1$$

$$(q_1, \epsilon, \perp, q_f, \epsilon) \quad q_1 \perp \xrightarrow{\epsilon} q_f$$



**Notación.** Dada una palabra  $A_1 A_2 \dots A_k \in \Gamma^+$  decimos que:

- ♦  $A_1 A_2 \dots A_k$  es un **stack** (contenido),
- ♦  $A_1$  es el **tope** del stack y
- ♦  $A_2 \dots A_k$  es la **cola** del stack.

**Definición.** Una **configuración** de  $\mathcal{P}$  es una tupla  $(q \cdot \gamma, w) \in (Q \cdot \Gamma^*, \Sigma^*)$  tal que:

- ♦  $q$  es el estado actual.
- ♦  $\gamma$  es el contenido del stack.
- ♦  $w$  es el contenido del input.

Decimos que una configuración:

$$(q \cdot \gamma, w) \in (Q \cdot \Gamma^*, \Sigma^*)$$

- ♦ es **inicial** si  $q \cdot \gamma = q_0 \cdot \perp$ .
- ♦ es **final** si  $q \cdot \gamma = q_f \cdot \epsilon$  con  $q_f \in F$  y  $w = \epsilon$ .

**Definición.** Se define la relación  $\vdash_{\mathcal{P}}$  de **siguiente-paso** entre configuraciones de  $\mathcal{P}$ :

$$(q_1 \cdot \gamma_1, w_1) \vdash_{\mathcal{P}} (q_2 \cdot \gamma_2, w_2)$$

si, y sólo si, existe una transición  $(q_1, a, A, q_2, \alpha) \in \Delta$  y  $\gamma \in \Gamma^*$  tal que:

- ♦  $w_1 = a \cdot w_2$

$$\diamond \gamma_1 = A \cdot \gamma$$


$$\diamond \gamma_2 = \alpha \cdot \gamma$$

Se define  $\vdash_{\mathcal{P}}^*$  como la clausura **refleja** y **transitiva** de  $\vdash_{\mathcal{P}}$ . En otras palabras:

$(q_1 \gamma_1, w_1) \vdash_{\mathcal{P}}^* (q_2 \gamma_2, w_2)$  si uno puede ir de  $(q_1 \gamma_1, w_1)$  a  $(q_2 \gamma_2, w_2)$  en 0 o más pasos.

### Ejemplo 5.2

Para la palabra  $w = aaabbb$ , tenemos la ejecución:



**Definiciones.**  $\mathcal{P}$  **acepta**  $w$  si, y sólo si,  $(q_0 \perp, w) \vdash_{\mathcal{P}}^* (q_f, \epsilon)$  para algún  $q_f \in F$ .

El **lenguaje aceptado** por  $\mathcal{P}$  se define como:

$$\mathcal{L}(\mathcal{P}) = \{w \in \Sigma^* \mid \mathcal{P} \text{ acepta } w\}$$

### Ejemplo 5.3

El lenguaje aceptado por el PDA utilizado en los ejemplos anteriores es  $\mathcal{L}(\mathcal{P}) = \{a^n b^n \mid n \geq 0\}$ .

#### 5.1.2. Versión alternativa

Esta definición de autómatas apilador es poco común pero trae algunas ventajas:

- ♦ Es un modelo que ayuda a entender mejor los algoritmos de evaluación para gramáticas.
- ♦ Es un modelo menos estándar pero mucho más sencillo.
- ♦ Al profe Cristian le gustó y lo encontró interesante.

**Definición.** Un **PDA alternativo** es una estructura:

$$\mathcal{D} = (Q, \Sigma, \Delta, q_0, F)$$

- ♦  $Q$  es un conjunto finito de **estados**.

- ♦  $\Sigma$  es el alfabeto del **input**.
- ♦  $q_0 \in Q$  es el estado **inicial**.
- ♦  $F$  es el conjunto de estados **finales**.
- ♦  $\Delta \subseteq Q^+ \times (\Sigma \cup \{\epsilon\}) \times Q^*$  es una **relación finita de transición**.

Intuitivamente, la transición:

$$(A_1 \dots A_i, a, B_1 \dots B_j) \in \Delta$$

si el autómata apilador tiene:

- ♦  $A_1 \dots A_i$  en el tope del stack y leyendo  $a$ ,

entonces:

- ♦ cambia el tope  $A_1 \dots A_i$  por  $B_1 \dots B_j$ .

En este tipo de autómata apilador, **no hay diferencia** entre estados y alfabeto del stack.

**Definición.** Una **configuración** de  $\mathcal{D}$  es una tupla

$$(q_1 \dots q_k, w) \in (Q^+, \Sigma^*)$$

tal que:

- ♦  $q_1 \dots q_k$  es el contenido del stack con  $q_1$  el tope del stack.
- ♦  $w$  es el contenido del input.

Decimos que una configuración:

- ♦  $(q_0, w)$  es **inicial**.
- ♦  $(Q_f, \epsilon)$  es **final** si  $q_f \in F$ .

**Definición.** Se define la relación  $\vdash_{\mathcal{D}}$  de **siguiente-paso** entre configuraciones de  $\mathcal{D}$ :

$$(\gamma_1, w_1) \vdash_{\mathcal{D}} (\gamma_2, w_2)$$

si, y sólo si, existe una transición  $(\alpha, a, \beta) \in \Delta$  y  $\gamma \in \Gamma^*$  tal que:

- ♦  $w_1 = a \cdot w_2$
- ♦  $\gamma_1 = \alpha \cdot \gamma$
- ♦  $\gamma_2 = \beta \cdot \gamma$

Se define  $\vdash_{\mathcal{D}}^*$  como la clausura **refleja** y **transitiva** de  $\vdash_{\mathcal{D}}$ .

**Definiciones.**  $\mathcal{D}$  **acepta**  $w$  si, y sólo si,  $(q_0, w) \vdash_{\mathcal{D}}^* (q_f, \epsilon)$  para algún  $q_f \in F$ . Además, el **lenguaje aceptado** por  $\mathcal{D}$  se define como:

$$\mathcal{L}(\mathcal{D}) = \{w \in \Sigma^* \mid \mathcal{D} \text{ acepta } w\}$$

**Ejemplo 5.4**

$$\mathcal{D} = (Q, \{a, b\}, \Delta, q_0, F)$$

♦  $Q = \{\perp, q_0, q_1, q_f\}$  y  $\Delta$ :

$(\perp, a, q_0 \perp)$	$\perp \xrightarrow{a} q_0 \perp$	$\perp$	
$(q_0, a, q_0 q_0)$	$q_0 \xrightarrow{a} q_0 q_0$	$q_0 \perp$	a
$(q_0, b, q_1)$	$q_0 \xrightarrow{a} q_1$	$q_0 q_0 \perp$	a
$(q_1 q_0, b, q_1)$	$q_1 q_0 \xrightarrow{b} q_1$	$q_0 q_0 q_0 \perp$	a
$(q_1 \perp, \epsilon, q_f)$	$q_1 \perp \xrightarrow{b} q_f$	$q_1 q_0 q_0 \perp$	b
		$q_1 q_0 \perp$	b
		$q_1 \perp$	b
		$q_f$	$\epsilon$

$$\mathcal{L}(\mathcal{D}) = \{a^n b^n \mid n \geq 1\}$$

**Teorema 11**

Para todo autómata apilador  $\mathcal{P}$  existe un autómata apilador alternativo  $\mathcal{D}$ , y viceversa, tal que:

$$\mathcal{L}(\mathcal{P}) = \mathcal{L}(\mathcal{D})$$

El teorema anterior nos dice que podemos usar ambos modelos de manera **equivalente**.

**5.2. Autómatas apiladores vs gramáticas libres de contexto**

¿En qué se parecen CFG a PDA?

Gramáticas libre de contexto		Autómatas apiladores
■ Terminales ( $\Sigma$ )		■ Alfabeto input ( $\Sigma$ )
■ Variables ( $V$ )		■ Alfabeto stack ( $\Gamma$ )
■ Producciones		■ Transiciones
■ $A \rightarrow \gamma$		■ $pA \xrightarrow{\zeta} q\gamma$
■ $A \rightarrow a$		■ $pA \xrightarrow{\zeta} q$
■ Derivaciones		■ Ejecuciones
■ Árbol de derivación		■ Stack

**Figura 6:** Gramáticas vs Autómatas apiladores

**Teorema 12**

Todo **lenguaje libre de contexto** puede ser descrito equivalentemente por:

- ♦ Una gramática libre de contexto (**CFG**).
- ♦ Un autómata apilador (**PDA**).



## 5.2.1. Desde CFG a PDA

Partimos enunciado un teorema:

**Teorema 13**

Para toda gramática libre de contexto  $\mathcal{G}$ , existe un **autómata apilador alternativo**  $\mathcal{D}$ , tal que:

$$\mathcal{L}(\mathcal{G}) = \mathcal{L}(\mathcal{D})$$

**Construcción  $\mathcal{D}$  desde  $\mathcal{G}$ .** Sea  $\mathcal{G} = (V, \Sigma, P, S)$  una CFG. Construimos un PDA alternativo  $\mathcal{D}$  que acepta  $\mathcal{L}(\mathcal{G})$ :

$$\mathcal{D} = (V \cup \Sigma \cup \{q_0, q_f\}, \Sigma, \Delta, q_0, \{q_f\})$$

La relación de transición  $\Delta$  se define como:

$$\begin{aligned} \Delta = & \{(q_0, \epsilon, S \cdot q_f)\} & \cup \\ & \{(X, \epsilon, \gamma) \mid X \rightarrow \gamma \in P\} & \cup \text{ (Expandir)} \\ & \{(a, a, \epsilon) \mid a \in \Sigma\} & \text{ (Reducir)} \end{aligned}$$

**Demostración  $\mathcal{L}(\mathcal{G}) = \mathcal{L}(\mathcal{D})$ .** Debemos demostrar dos direcciones:  $\mathcal{L}(\mathcal{G}) \subseteq \mathcal{L}(\mathcal{D})$  y  $\mathcal{L}(\mathcal{D}) \subseteq \mathcal{L}(\mathcal{G})$ .

**Demostración  $\mathcal{L}(\mathcal{G}) \subseteq \mathcal{L}(\mathcal{D})$ .** Para cada  $w \in \mathcal{L}(\mathcal{G})$  debemos encontrar una ejecución de aceptación de  $\mathcal{D}$  sobre  $w$ . ¿Cómo encontramos esta ejecución? La idea es que para cada árbol de derivación  $\mathcal{T}$  de  $\mathcal{G}$  sobre  $w$ , construimos una ejecución de  $\mathcal{D}$  sobre  $w$  que recorre el árbol  $\mathcal{T}$  **en profundidad** (DFS). Por tanto, debemos usar **inducción** sobre la altura del árbol  $\mathcal{T}$ .

**Hipótesis de inducción.** Para todo árbol de derivación  $\mathcal{T}$  de  $\mathcal{G}$  con **altura**  $h$  tal que:

♦ la raíz de  $\mathcal{T}$  es  $X$ , y

♦  $\mathcal{T}$  produce la palabra  $w$

entonces  $(X \cdot \gamma, w) \vdash_{\mathcal{D}}^* (\gamma, \epsilon)$  para todo  $\gamma \in Q^+$ .

**Caso base:**  $h = 1$ . Si  $\mathcal{T}$  tiene altura 1, entonces:

♦  $\mathcal{T}$  produce la palabra  $w = a$  para algún  $a \in \Sigma$  y

♦  $\mathcal{T}$  consiste de un nodo  $X$  y un hijo  $a$  con  $X \rightarrow a$ .

Entonces para todo  $\gamma \in Q^+$ :


$$(X \cdot \gamma, a) \vdash_{\mathcal{D}} (a \cdot \gamma, a) \vdash_{\mathcal{D}} (\gamma, \epsilon)$$

es una ejecución de  $\mathcal{D}$  sobre  $a$ .

**Caso inductivo:**  $h = n$ . Suponemos que el árbol de derivación  $\mathcal{T}$  de  $\mathcal{G}$  tiene **altura**  $n$  tal que:

- ♦ la raíz de  $\mathcal{T}$  es  $X$ , y
- ♦  $\mathcal{T}$  produce la palabra  $w$ .

**Sin pérdida de generalidad**, suponga que  $\mathcal{T}$  es de la forma:



donde  $w = u \cdot v$  y  $X \rightarrow YZ$ . Por HI, se tiene que para todo  $\gamma_1, \gamma_2 \in Q^+$ :

$$\begin{aligned} (Y \cdot \gamma_1, u) &\vdash_{\mathcal{D}}^* (\gamma_1, \epsilon) \\ (Z \cdot \gamma_2, v) &\vdash_{\mathcal{D}}^* (\gamma_2, \epsilon) \end{aligned}$$

Para  $\gamma \in Q^+$  **construimos** la siguiente ejecución de  $\mathcal{D}$  sobre  $w = uv$ :

$$(X \cdot \gamma, uv) \vdash_{\mathcal{D}} (YZ \cdot \gamma, uv) \vdash_{\mathcal{D}}^* (Z \cdot \gamma, v) \vdash_{\mathcal{D}}^* (\gamma, \epsilon)$$

■

La demostración de  $\mathcal{L}(\mathcal{D}) \subseteq \mathcal{L}(\mathcal{G})$  se deja como ejercicio propuesto al lector.

### 5.2.2. Desde PDA a CFG

Partimos enunciando el siguiente teorema:

#### Teorema 14

Para todo autómata apilador  $\mathcal{P}$ , existe una gramática libre de contexto  $\mathcal{G}$  tal que:

$$\mathcal{L}(\mathcal{P}) = \mathcal{L}(\mathcal{G})$$

**Demostración**  $\mathcal{L}(\mathcal{P}) = \mathcal{L}(\mathcal{G})$ . Sea  $\mathcal{P} = (Q, \Sigma, \Gamma, \Delta, q_0, \perp, F)$  un PDA (normal). Los pasos a seguir son:

1. Convertir  $\mathcal{P}$  a un PDA  $\mathcal{P}'$  con **UN solo estado**.
2. Convertir  $\mathcal{P}'$  a una gramática libre de contexto  $\mathcal{G}$ .

**Paso 1.** Sea  $\mathcal{P} = (Q, \Sigma, \Gamma, \Delta, q_0, \perp, F)$  un PDA. Podemos analizar:

- ♦ ¿Por qué NO necesitamos la información de los estados?
- ♦ ¿Cómo guardamos la información de los estados en el stack?

Esto conlleva a la siguiente pregunta: *Si el PDA está en el estado  $p$  y en el tope del stack hay una  $A$ , ¿a cuál estado llegaré al remover  $A$  del stack?*

La solución a esta pregunta es que podemos **adivinar** (no-determinismo) el estado que vamos a llegar cuando removamos  $A$  del stack.

**Sin pérdida de generalidad**, podemos asumir que

1. Todas las transiciones son de la forma:

$$qA \xrightarrow{c} pB_1B_2 \quad \text{o} \quad qA \xrightarrow{c} p\epsilon$$

con  $c \in (\Sigma \cup \{\epsilon\})$ .

2. Existe  $q_f \in Q$  tal que si  $w \in \mathcal{L}(\mathcal{P})$  entonces:

$$(q_0 \perp, w) \vdash_{\mathcal{D}}^* (q_f, \epsilon)$$

Estos dos puntos nos aseguran que siempre llegamos al **mismo estado**  $q_f$ . Luego, construimos el autómata apilador  $\mathcal{P}'$  con **un solo estado**:

$$\mathcal{P}' = (\{q\}, \Sigma, \Gamma', \Delta', \{q\}, \perp', \{q\})$$

♦  $\Gamma' = Q \times \Gamma \times Q$ .

“ $(p, A, q) \in \Gamma'$  si desde  $p$  leyendo  $A$  en el tope del stack llegamos a  $q$  al hacer pop de  $A$ ”.

♦  $\perp' = (q_0, \perp, q_f)$ .

“El autómata parte en  $q_0$  y al hacer pop de  $\perp$  llegará a  $q_f$ ”.

♦ Si  $pA \xrightarrow{c} p'B_1B_2 \in \Delta$  con  $c \in (\Sigma \cup \{\epsilon\})$ , entonces **para todo**  $p_1, p_2 \in Q$ :

$$q(p, A, p_2) \xrightarrow{c} q(p', B_1, p_1) \quad (p_1, B_2, p_2) \in \Delta'$$

♦ Si  $pA \xrightarrow{c} p' \in \Delta$  con  $c \in (\Sigma \cup \{\epsilon\})$ , entonces:

$$q(p, A, p') \xrightarrow{c} q \in \Delta'$$

**Hipótesis de inducción (en el número de pasos  $n$ ).** Para todo  $p, p' \in Q$ ,  $A \in \Gamma$  y  $w \in \Sigma^*$  se cumple que:

$$(pA, w) \vdash_{\mathcal{P}}^n (p', \epsilon) \quad \text{si, y solo si,} \quad (q(p, A, p'), w) \vdash_{\mathcal{P}'}^n (q, \epsilon)$$

donde  $\vdash_{\mathcal{P}}^n$  es la relación de **siguiente-paso** de  $\mathcal{P}$   $n$ -veces.

Si demostramos esta hipótesis, habremos demostrado que  $\mathcal{L}(\mathcal{P}) = \mathcal{L}(\mathcal{P}')$ . ¿Por qué?

**Caso base:**  $n = 1$ . Para todo  $p, p' \in Q$ , y  $A \in \Gamma$  se cumple que:

$$(pA, c) \vdash_{\mathcal{P}} (p', \epsilon) \quad \text{si, y solo si,} \quad (q(p, A, p'), c) \vdash_{\mathcal{P}'} (q, \epsilon)$$

para todo  $c \in (\Sigma \cup \{\epsilon\})$ .

**Caso inductivo.** **Sin pérdida de generalidad**, suponga que  $pA \xrightarrow{a} p_1A_1A_2$  y  $w = auv$ , entonces

$$(pA, \underbrace{auv}_w) \vdash_{\mathcal{P}}^n (p', \epsilon) \quad \text{ssi} \quad (pA, auv) \vdash_{\mathcal{P}} (p_1A_1A_2, uv) \vdash_{\mathcal{P}}^i (p_2A_2, v) \vdash_{\mathcal{P}}^j (p', \epsilon)$$

$$\text{ssi} \quad (p_1A_1, u) \vdash_{\mathcal{P}}^i (p_2, \epsilon) \quad \text{y} \quad (p_2A_2, v) \vdash_{\mathcal{P}}^j (p', \epsilon)$$

$$\text{ssi} \quad (q(p_1, A_1, p_2), u) \vdash_{\mathcal{P}'}^i (q, \epsilon) \quad \text{y} \quad (q(p_2, A_2, p'), v) \vdash_{\mathcal{P}'}^j (q, \epsilon)$$

$$\text{ssi} \quad (q(p, A, p'), auv) \vdash_{\mathcal{P}} (q(p_1, A_1, p_2)(p_2, A_2, q), uv) \vdash_{\mathcal{P}}^{i+j} (q, \epsilon)$$

■

**Paso 2.** Sea  $\mathcal{P} = (\{q\}, \Sigma, \Gamma, \Delta, q, \perp, \{q\})$  un PDA con **UN solo estado**. Construimos la gramática:

$$\mathcal{G} = (V, \Sigma, P, \perp)$$

♦  $V = \Gamma$ .

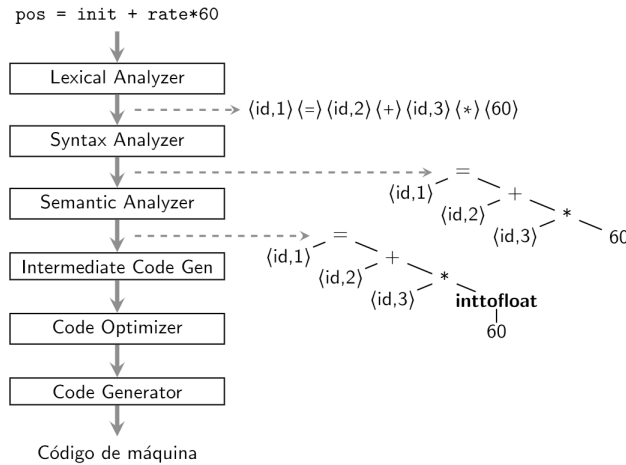
♦ Si  $qA \xrightarrow{\epsilon} q\alpha \in \Delta$  entonces  $A \rightarrow \alpha \in P$

♦ Si  $qA \xrightarrow{a} q\alpha \in \Delta$  entonces  $A \rightarrow a\alpha \in P$

La demostración de este paso queda como ejercicio propuesto al lector.

### 5.3. Parsing: cómputo de First y Follow

**Recordatorio.** La **sintaxis** de un lenguaje es un conjunto de reglas que describen los programas válidos que tienen significado. Por otro lado, la **semántica** de un lenguaje define el significado de un programa correcto según la sintaxis.



**Figura 7:** La estructura de un compilador

Lo que se busca es un proceso de **verificación de sintaxis** de un programa, y que entregue la estructura del mismo (árbol de parsing). Consta de tres etapas:

1. Análisis léxico (**Lexer**).
2. Análisis sintáctico (**Parser**).
3. Análisis semántico.

En una sección anterior vimos el **Lexer**. Ahora, veremos como hacer el **Parser**.

Informalmente: “*dado una secuencia de tokens  $w'$  y una gramática  $\mathcal{G}$ , construir un árbol de derivación (parsing) de  $\mathcal{G}$  para  $w$* ”.

Con el **árbol de derivación** habremos verificado la sintaxis y obtenido la estructura.

**Ejemplo 5.5: Parsing de gramática**


$$E \rightarrow (E + E) \mid (E * E) \mid \text{num}$$

Para un input  $w = ((43 + 56) * 27)$ :

- ♦ Convertimos  $w$  en una secuencia de **tokens**:

$$w' = ((\text{num} + \text{num}) * \text{num})$$

- ♦ Construimos un árbol de **parsing** para  $w'$ :



**Problema de parsing.** Dado una palabra  $w$  y dado una gramática  $\mathcal{G}$ , generar un árbol de parsing  $\mathcal{T}$  de  $\mathcal{G}$  para  $w$ . ¿Ya sabemos resolver este problema? El algoritmo CKY nos permite hacer esto, pero:

- ♦ es impracticable para grandes inputs.
- ♦ múltiples pasadas sobre el input.

Deseamos hacer parsing en **tiempo lineal** en el tamaño del input. ¿Quién nos puede rescatar ante tal problema? Efectivamente, los autómatas apiladores.

Recordemos que, para una gramática  $\mathcal{G} = (V, \Sigma, P, S)$  **podemos construir un PDA alternativo**  $\mathcal{D}$  que acepta  $\mathcal{L}(\mathcal{G})$ :

$$\mathcal{D} = (V \cup \Sigma \cup \{q_0, q_f\}, \Sigma, \Delta, q_0, \{q_f\})$$

La relación de transición  $\Delta$  se define como:

$$\begin{aligned} \Delta = & \{(q_0, \epsilon, S \cdot q_f)\} && \cup \\ & \{(X, \epsilon, \gamma) \mid X \rightarrow \gamma \in P\} && \cup \quad \textbf{(Expandir)} \\ & \{(a, a, \epsilon) \mid a \in \Sigma\} && \textbf{(Reducir)} \end{aligned}$$

Con esto, nos encontramos con otro **problema**: hay muchas alternativas para **expandir**. ¿Cómo elegir entonces la siguiente producción para expandir? Por ejemplo, si tenemos la regla  $X \rightarrow \alpha \mid \beta$ , ¿cómo elegir entre  $\alpha$  o  $\beta$ ?

Queremos elegir la **próxima producción**  $X \rightarrow \gamma$  de tal manera que, si existe una derivación para el input, entonces  $X \rightarrow \gamma$  **es parte de esa derivación**:

$$\text{si } S \xrightarrow{\text{lm}}^* uX\gamma' \xrightarrow{\text{lm}}^* uv, \text{ entonces } \gamma\gamma' \xrightarrow{\text{lm}}^* v$$

Necesitamos **mirar las siguientes letras en**  $v$  y ver si pueden ser producidas por  $\alpha$  o  $\beta$ . Para esto, ocuparemos los conceptos de **first** y **follow**.

### 5.3.1. Prefijos

**Definición.** Sea  $\Sigma$  un alfabeto finito. Para un  $k \geq 0$ , se define

$$\begin{aligned}\Sigma^{\leq k} &= \bigcup_{i=0}^k \Sigma^i \\ \Sigma_{\#}^{\leq k} &= \Sigma^{\leq k} \cup (\Sigma^{\leq k-1} \cdot \{\#\})\end{aligned}$$

#### Ejemplo 5.6

Para  $\Sigma = \{a, b\}$ :

- ♦  $\Sigma^{\leq 2} = \{\epsilon, a, b, aa, ab, ba, bb\}$
- ♦  $\Sigma_{\#}^{\leq 2} = \{\epsilon, a, b, aa, ab, ba, bb\} \cup \{\#, a\#, b\#\}$

El símbolo  $\#$  representará un EOF (End Of File), marcando el **fin de una palabra**.

**Definición.** Para una palabra  $w = a_1 a_2 \dots a_n \in \Sigma^*$  se define el  $k$ -**prefijo** de  $w$  como:

$$w|_k = \begin{cases} a_1 \dots a_n & \text{si } n \leq k \\ a_1 \dots a_k & \text{si } k < n \end{cases}$$

Definimos la  $k$ -**concatenación**  $\odot_k$  entre strings  $u, v \in \Sigma$  como:

$$u \odot_k v = (u \cdot v)|_k$$

#### Ejemplo 5.7

Sea  $\Sigma = \{a, b\}$ , entonces:

- ♦  $(abaa)|_2 = ab \quad (ab)|_2 = ab \quad (a)|_2 = a \quad (\epsilon)|_2 = \epsilon$
- ♦  $a \odot_2 baa = (abaa)|_2 = ab$
- ♦  $bba \odot_2 a = (bbaa)|_2 = bb$
- ♦  $b \odot_2 \epsilon = (b)|_2 = b$

Extendemos estas operaciones para lenguajes  $L, L_1, L_2 \subseteq \Sigma^*$  como:

$$\begin{aligned}L|_k &= \{w|_k \mid w \in L\} \\ L_1 \odot_k L_2 &= \{w_1 \odot_k w_2 \mid w_1 \in L_1 \text{ y } w_2 \in L_2\}\end{aligned}$$

#### Ejemplo 5.8

- ♦  $((ab)^*)|_3 = \{\epsilon, ab, aba\}$
- ♦  $(a)^* \odot_3 (ab)^* = \{\epsilon, a, aa, aaa, ab, aba, aab\}$

Podemos decir que los operadores  $|_k$  y  $\odot_k$  “miran” hasta un prefijo  $k$ .

**Propiedades.** Para todo  $k \geq 1$  y  $L_1, L_2, L_3 \subseteq \Sigma^*$ :

1.  $L_1 \odot_k (L_2 \odot_k L_3) = (L_1 \odot_k L_2) \odot_k L_3$
2.  $L_1 \odot_k \{\epsilon\} = \{\epsilon\} \odot_k L_1 = L_1|_k$
3.  $(L_1 L_2)|_k = L_1|_k \odot_k L_2|_k$
4.  $L_1 \odot_k (L_2 \cup L_3) = (L_1 \odot_k L_2) \cup (L_1 \odot_k L_3)$

La demostración de estas propiedades queda como ejercicio propuesto al lector.

### 5.3.2. First y Follow

Sea  $\mathcal{G} = (V, \Sigma, P, S)$  una gramática libre de contexto y  $k \geq 1$ .

**Definición.** Se define la función  $\text{first}_k : (V \cup \Sigma)^* \rightarrow 2^{\Sigma^{\leq k}}$  tal que, para  $\gamma \in (V \cup \Sigma)^*$ :

$$\text{first}_k(\gamma) = \{u|_k \mid \gamma \xRightarrow{*} u\}$$

#### Ejemplo 5.9

$$E \rightarrow (E + E) \mid (E * E) \mid n$$

- ♦  $\text{first}_1(E) = \{(\, , n\}$
- ♦  $\text{first}_2(E) = \{n, (n, ((\}$
- ♦  $\text{first}_3(E) = \{n, (n+, (n*, ((n, (((\}$


**Definición.** Se define la función  $\text{follow}_k : V \rightarrow 2^{\Sigma^{\leq k}_{\#}}$  como:

$$\text{follow}_k(X) = \{w \mid S \xRightarrow{*} \alpha X \beta \text{ y } w \in \text{first}_k(\beta\#)\}$$

#### Ejemplo 5.10

$$E \rightarrow (E + E) \mid (E * E) \mid n$$

- ♦  $\text{follow}_1(E) = \{\#, +, *, )\}$
- ♦  $\text{follow}_2(E) = \{\#, )\#, ), )+, )*, +(, *(, +n, *n\}$



**Figura 8:** Representación de first y follow

### 5.3.3. Calcular First

Sea  $\mathcal{G} = (V, \Sigma, P, S)$  una gramática libre de contexto y  $k \geq 1$ .

**Proposición.** Para  $X_1, \dots, X_n \in (V \cup \Sigma)$ :

$$\mathbf{first}_k(X_1 \dots X_n) = \mathbf{first}_k(X_1) \odot_k \dots \odot_k \mathbf{first}_k(X_n)$$

**Demostración.** Defina  $\mathcal{L}(X) = \{w \mid X \xRightarrow{*} w\}$  y  $\mathcal{L}(\gamma) = \{w \mid \gamma \xRightarrow{*} w\}$ . Notar que  $\mathbf{first}_k(\gamma) = \mathcal{L}(\gamma)|_k$ , por lo tanto, tenemos que

$$\begin{aligned} \mathbf{first}_k(X_1 \dots X_n) &= \mathcal{L}(X_1 \dots X_n)|_k \\ &= (\mathcal{L}(X_1) \cdot \mathcal{L}(X_2) \cdot \dots \cdot \mathcal{L}(X_n))|_k \\ &= \mathcal{L}(X_1)_k \odot_k \mathcal{L}(X_2)_k \odot_k \dots \odot_k \mathcal{L}(X_n)_k \\ &= \mathbf{first}_k(X_1) \odot_k \dots \odot_k \mathbf{first}_k(X_n) \end{aligned}$$

■

En particular, tenemos que:

$$\mathbf{first}_k(X) = \bigcup_{X \rightarrow X_1 \dots X_n \in P} \mathbf{first}_k(X_1) \odot_k \dots \odot_k \mathbf{first}_k(X_n)$$

Definimos el siguiente **programa recursivo** para todo  $X \in (V \cup \Sigma)$ :

$$\begin{aligned} \mathbf{first}_k^0(X) &:= \bigcup_{X \rightarrow w \in P} w|_k \\ \mathbf{first}_k^i(X) &:= \bigcup_{X \rightarrow X_1 \dots X_n \in P} \mathbf{first}_k^{i-1}(X_1) \odot_k \dots \odot_k \mathbf{first}_k^{i-1}(X_n) \end{aligned}$$

Es fácil ver que:

- ♦  $\mathbf{first}_k^{i-1}(X) \subseteq \mathbf{first}_k^i(X)$  para todo  $i > 1$ .
- ♦ Como  $\mathbf{first}_k(X) \subseteq \Sigma^{\leq k}$ , entonces para algún  $i \leq k \cdot |\Sigma|^k \cdot |V|$  tendremos:

$$\mathbf{first}_k^j(X) = \mathbf{first}_k^{j+1}(X) \text{ para todo } j \geq i$$

#### Teorema 15

Sea  $i^*$  el menor número tal que  $\mathbf{first}_k^{i^*}(X) = \mathbf{first}_k^{i^*+1}(X)$  para todo  $X \in V$ . Entonces, para todo  $X \in V$ :

$$\mathbf{first}_k^{i^*}(X) = \mathbf{first}_k(X)$$

La demostración del teorema anterior queda como ejercicio propuesto para el lector. Una idea para la dirección  $\subseteq$ , es demostrar por inducción que  $\mathbf{first}_k^i(X) \subseteq \mathbf{first}_k(X)$ . Para la dirección  $\supseteq$ , una idea es demostrar por inducción que si  $X \xRightarrow{*} w$ , entonces  $w|_k \in \mathbf{first}_k^i(X)$  para algún  $i$ .

**Algoritmo.** A continuación se presenta un algoritmo para calcular  $\mathbf{first}_k$ :

- ♦ **Input:** Gramática  $\mathcal{G} = (V, \Sigma, P, S)$  y  $k \geq 1$ .
- ♦ **Output:** Todos los conjuntos  $\mathbf{first}_k(X)$  para todo  $X \in (V \cup \Sigma)$ .



**Function**  $\text{CalcularFirst}(\mathcal{G}, k)$ :

```

foreach  $a \in \Sigma$  do
  |  $\text{first}_k^0(a) := \{a\}$ 
foreach  $X \in V$  do
  |  $\text{first}_k^0(X) := \cup_{X \rightarrow w \in P} w|_k$ 
 $i := 0$ 
repeat
  |  $i := i + 1$ 
  | foreach  $a \in \Sigma$  do
    |  $\text{first}_k^i(a) := \{a\}$ 
  | foreach  $X \in V$  do
    |  $\text{first}_k^i(X) := \bigcup_{X \rightarrow X_1 \dots X_n \in P} \text{first}_k^{i-1}(X_1) \odot_k \dots \odot_k \text{first}_k^{i-1}(X_n)$ 
until  $\text{first}_k^i(X) = \text{first}_k^{i-1}(X)$  para todo  $X \in (V \cup \Sigma)$ 
return  $\{\text{first}_k(X)\}_{X \in (V \cup \Sigma)}$ 

```

#### 5.3.4. Calcular Follow

Sea  $\mathcal{G} = (V, \Sigma, P, S)$  una gramática libre de contexto y  $k \geq 1$ . Si consideramos  $X \neq S$ :

$$\begin{aligned}
 \text{follow}_k(X) &= \bigcup_{S \xrightarrow{*} \alpha X \beta} \text{first}_k(\beta \#) \\
 &= \bigcup_{S \xrightarrow{*} \alpha Y \beta \Rightarrow \alpha \alpha' X \beta' \beta} \text{first}_k(\beta' \beta \#) \\
 &= \bigcup_{Y \rightarrow \alpha' X \beta'} \bigcup_{S \xrightarrow{*} \alpha Y \beta} \text{first}_k(\beta' \beta \#) \\
 &= \bigcup_{Y \rightarrow \alpha' X \beta'} \bigcup_{S \xrightarrow{*} \alpha Y \beta} \text{first}_k(\beta') \odot_k \text{first}_k(\beta \#) \\
 &= \bigcup_{Y \rightarrow \alpha' X \beta'} \text{first}_k(\beta') \odot_k \bigcup_{S \xrightarrow{*} \alpha Y \beta} \text{first}_k(\beta \#) \\
 &= \bigcup_{Y \rightarrow \alpha' X \beta'} \text{first}_k(\beta') \odot_k \text{follow}_k(Y)
 \end{aligned}$$

Si consideramos  $X = S$ :

$$\begin{aligned}
 \text{follow}_k(S) &= \{\#\} \cup \bigcup_{S \xrightarrow{*} \alpha S \beta} \text{first}_k(\beta \#) \\
 &= \{\#\} \cup \bigcup_{S \xrightarrow{*} \alpha Y \beta \Rightarrow \alpha \alpha' S \beta' \beta} \text{first}_k(\beta' \beta \#) \\
 &= \{\#\} \cup \bigcup_{Y \rightarrow \alpha' S \beta'} \text{first}_k(\beta') \odot_k \text{follow}_k(Y)
 \end{aligned}$$

Dado lo anterior, podemos definir el siguiente teorema.

**Teorema 16**

Sea  $\mathcal{G} = (V, \Sigma, P, S)$  una gramática libre de contexto y  $k \geq 1$ . Entonces:

$$\text{Para } X \neq S: \quad \text{follow}_k(X) = \bigcup_{Y \rightarrow \alpha X \beta} \text{first}_k(\beta) \odot_k \text{follow}_k(Y)$$

$$\text{Para } X = S: \quad \text{follow}_k(S) = \{\#\} \cup \bigcup_{Y \rightarrow \alpha S \beta} \text{first}_k(\beta) \odot_k \text{follow}_k(Y)$$

Definimos el siguiente **programa recursivo** para todo  $X \in V$ :

$$\text{Para } X \neq S: \quad \text{follow}_k^0(X) := \emptyset$$

$$\text{Para } X = S: \quad \text{follow}_k^0(S) := \{\#\}$$

$$\text{Para } X \neq S: \quad \text{follow}_k^i(X) := \bigcup_{Y \rightarrow \alpha X \beta} \text{first}_k(\beta) \odot_k \text{follow}_k^{i-1}(Y)$$

$$\text{Para } X = S: \quad \text{follow}_k^i(S) := \{\#\} \cup \bigcup_{Y \rightarrow \alpha S \beta} \text{first}_k(\beta) \odot_k \text{follow}_k^{i-1}(Y)$$

Similar al caso de  $\text{first}_k$ , es fácil ver que:

♦  $\text{follow}_k^{i-1}(X) \subseteq \text{follow}_k^i(X)$  para todo  $i > 1$ .

♦ Como  $\text{follow}_k(X) \subseteq \Sigma^{\leq k}$ , entonces para algún  $i \leq k \cdot |\Sigma|^k \cdot |V|$ :

$$\text{follow}_k^j(X) = \text{follow}_k^{j+1}(X) \quad \text{para todo } j \geq i$$

**Teorema 17**

Sea  $i^*$  el menor número tal que  $\text{follow}_k^{i^*}(X) = \text{follow}_k^{i^*+1}(X)$  para todo  $X \in V$ . Entonces, para todo  $X \in V$ :

$$\text{follow}_k^{i^*}(X) = \text{follow}_k(X)$$

La demostración de este teorema se deja como ejercicio propuesto al lector.

Con todo lo anterior, podemos calcular  $\text{follow}_k(X)$  con un algoritmo similar que  $\text{first}_k(X)$ . Respecto a la eficiencia de este tipo de algoritmos:

♦ Toman  $\mathcal{O}(k \cdot |\Sigma|^k \cdot |V|)$  en el peor caso.

♦ Si  $k = 1$ , el número de repeticiones será  $\mathcal{O}(|\Sigma| \cdot |V|)$  y el tiempo del algoritmo será polinomial en  $|\mathcal{G}|$  en el peor caso. Incluso, se puede hacer en tiempo  $\mathcal{O}(|V| \cdot |P|)$  en total.

**5.4. Gramáticas LL**

Volvamos a la idea de buscar un algoritmo que haga parsing en **tiempo lineal**. Para esto, contruíamos un autómata apilador alternativo  $\mathcal{D}$  al cual le expandíamos sus producciones. ¿El problema? No sabemos como elegir que producciones expandir. Debido a lo anterior, introducimos los conceptos de **first** y **follow**. Así que, si tenemos una producción de la forma  $X \rightarrow \alpha \mid \beta$ , ¿cómo elegir entre  $\alpha$  o  $\beta$ ?

**Estrategia (intuición).** La idea es la siguiente:

1. Mirar  $k$  símbolos del resto del input  $v$  ( $k$ -lookahead).
2. Usar  $v|_k$  y decidir cuál regla  $X \rightarrow \gamma$  elegimos para expandir.

La caracterización de las gramáticas que cumplen las propiedades anteriores se denominan **Gramáticas LL( $k$ )**, donde

- ♦ **Primera L**: leer el input de izquierda a derecha (**Left-right**).
- ♦ **Segunda L**: producir una derivación por la izquierda (**Leftmost**).
- ♦ **Parámetro  $k$** : el número de letras en adelante que utiliza (**lookahead**).

#### 5.4.1. Definición Gramáticas LL

Sea  $\mathcal{G} = (V, \Sigma, P, S)$  una gramática libre de contexto y  $k \geq 1$ .

**Definición.** Decimos que  $\mathcal{G}$  es una gramática LL( $k$ ) si para todas las derivaciones:

- ♦  $S \xRightarrow[\text{lm}]{*} uY\beta \Rightarrow_{\text{lm}} u\gamma_1\beta \xRightarrow[\text{lm}]{*} uv_1$
- ♦  $S \xRightarrow[\text{lm}]{*} uY\beta \Rightarrow_{\text{lm}} u\gamma_2\beta \xRightarrow[\text{lm}]{*} uv_2$  y
- ♦  $v_1|_k = v_2|_k$

entonces se cumple que  $\gamma_1 = \gamma_2$ .

Notar que la elección de  $Y \rightarrow \gamma$  depende de  $Y, v|_k$  y  $u$ .

#### Ejemplo 5.11: Gramáticas LL(1)

$$\mathcal{G}_1: S \rightarrow (S) \mid n$$

$$\begin{array}{ccccccc} S & \xRightarrow[\text{lm}]{*} & \overbrace{(\dots)}^u \overbrace{(S)}^Y \overbrace{\dots)}^\beta & \Rightarrow_{\text{lm}} & (\dots(\gamma_1)\dots) & \xRightarrow[\text{lm}]{*} & \overbrace{(\dots)}^u \overbrace{(v'_1)\dots}^{v_1} \\ & & & \Rightarrow_{\text{lm}} & (\dots(\gamma_2)\dots) & \xRightarrow[\text{lm}]{*} & \underbrace{(\dots)}_u \underbrace{(v'_2)\dots}_{v_2} \end{array}$$

- ♦ Si  $v_1|_1 = v_2|_1 = n$ , entonces  $\gamma_1 = \gamma_2 = n$ .
- ♦ Si  $v_1|_1 = v_2|_1 = ($ , entonces  $\gamma_1 = \gamma_2 = (S)$ .

En ambos casos, tenemos que  $\gamma_1 = \gamma_2$  y  $\mathcal{G}_1$  es una gramática LL(1).

$$\begin{array}{lcl} \mathcal{G}_2: S & \rightarrow & (X) \mid n \\ X & \rightarrow & SX \mid \epsilon \end{array}$$

$$\begin{array}{ccccccc} S & \xRightarrow[\text{lm}]{*} & uX\beta & \Rightarrow_{\text{lm}} & u\gamma_1\beta & \xRightarrow[\text{lm}]{*} & uv_1 \\ & & & \Rightarrow_{\text{lm}} & u\gamma_2\beta & \xRightarrow[\text{lm}]{*} & uv_2 \end{array}$$

- ♦ Si  $v_1|_1 = v_2|_1 = ($  o ' $n$ ', entonces  $\gamma_1 = \gamma_2 = SX$ .
- ♦ Si  $v_1|_1 = v_2|_1 = )$ , entonces  $\gamma_1 = \gamma_2 = \epsilon$ .

Por lo tanto, tenemos que  $\gamma_1 = \gamma_2$  y  $\mathcal{G}_2$  es **también** una gramática LL(1).

**Ejemplo 5.12: Gramática NO LL(1) pero si LL(2)**

$$\begin{aligned}
 \mathcal{G}_3: \quad S &\rightarrow (X) \mid n + S \mid n \\
 X &\rightarrow SX \mid \epsilon
 \end{aligned}$$

$$\begin{array}{c}
 S \xRightarrow[\text{lm}]{*} \overbrace{(S X)}^{u \ Y \ \beta} \Rightarrow_{\text{lm}} \overbrace{(n + S X)}^{\gamma_1} \xRightarrow[\text{lm}]{*} \overbrace{(n + n)}^{u \ v_1} \\
 \Rightarrow_{\text{lm}} \overbrace{(n X)}^{\gamma_2} \xRightarrow[\text{lm}]{*} \overbrace{(n)}^{u \ v_2}
 \end{array}
 \quad
 \begin{array}{c}
 S \xRightarrow[\text{lm}]{*} uS\beta \Rightarrow_{\text{lm}} u\gamma_1\beta \xRightarrow[\text{lm}]{*} uv_1 \\
 \Rightarrow_{\text{lm}} u\gamma_2\beta \xRightarrow[\text{lm}]{*} uv_2
 \end{array}$$

Como  $v_1|_1 = v_2|_1 = n$  pero  $\gamma_1 \neq \gamma_2$ , entonces  $\mathcal{G}_3$  NO es una gramática LL(1).

- ♦ Si  $v_1|_2 = v_2|_2 = n+$ , entonces  $\gamma_1 = \gamma_2 = n + S$ .
- ♦ Si  $v_1|_1 = v_2|_1 = na$ , con  $a \neq +$ , entonces  $\gamma_1 = \gamma_2 = n$ .

Por lo tanto, tenemos que  $\gamma_1 = \gamma_2$  y entonces  $\mathcal{G}_3$  es LL(2).

**Ejemplo 5.13: Gramática NO LL( $k$ )**

$$\begin{aligned}
 \mathcal{G}_4: \quad S &\rightarrow (X) \mid (X)^{\wedge e} \mid n + S \mid n \\
 X &\rightarrow SX \mid \epsilon
 \end{aligned}$$

$$\begin{array}{c}
 S \xRightarrow[\text{lm}]{*} \overbrace{(S X)}^{u \ Y \ \beta} \Rightarrow_{\text{lm}} \overbrace{((S)^{\wedge e} X)}^{\gamma_1} \xRightarrow[\text{lm}]{*} \overbrace{((\dots(n)\dots)^{\wedge e})}^{u \ v_1} \\
 \Rightarrow_{\text{lm}} \overbrace{((S) X)}^{\gamma_2} \xRightarrow[\text{lm}]{*} \overbrace{((\dots(n)\dots))}^{u \ v_2}
 \end{array}$$

Como  $v_1|_k = v_2|_k = (\dots)^k$  pero  $\gamma_1 \neq \gamma_2$ , entonces  $\mathcal{G}_4$  NO es una gramática LL( $k$ ) para todo  $k$ .

**Ejemplo 5.14: Gramática NO LL( $k$ ) transformada en LL(2)**

La gramática  $\mathcal{G}_4$  del ejemplo anterior se puede transformar para que sea LL(2) de la siguiente manera:

$$\begin{aligned}
 \mathcal{G}'_4: \quad S &\rightarrow (XY \mid n + S \mid n \\
 X &\rightarrow SX \mid \epsilon \\
 Y &\rightarrow ) \mid )^{\wedge e}
 \end{aligned}$$

Queda como ejercicio para el lector demostrar que  $\mathcal{G}'_4$  es LL(2).

**Ejemplo 5.15: Lenguaje NO LL( $k$ )**

$$\begin{array}{ll}
\mathcal{G}_5: & S \rightarrow X \mid Y \\
& X \rightarrow aXb \mid 0 \\
& Y \rightarrow aYbb \mid 1
\end{array}
\quad
\mathcal{L}(\mathcal{G}_5) = \{a^n 0 b^n \mid n \geq 0\} \cup \{a^n 1 b^{2n} \mid n \geq 0\}$$

$$\begin{array}{ccccc}
S & \xRightarrow[\text{lm}]{*} & S & \Rightarrow & X & \xRightarrow[\text{lm}]{*} & a^k 0 b^k \\
& & & \Rightarrow & Y & \xRightarrow[\text{lm}]{*} & a^k 1 b^{2k}
\end{array}$$

Para todo  $k \geq 1$ , se tiene que  $\mathcal{G}_5$  NO es una gramática LL( $k$ ).

Es posible demostrar que, para toda gramática  $\mathcal{G}$  con  $\mathcal{L}(\mathcal{G}_5) = \mathcal{L}(\mathcal{G})$ ,  $\mathcal{G}$  NO es una gramática LL( $k$ ) para todo  $k \geq 1$ .

**5.4.2. Caracterización LL**

Para esta parte es importante manejar las definiciones de prefijos vistas en la sección 5.3.1.

Sea  $\mathcal{G} = (V, \Sigma, P, S)$  una gramática libre de contexto **reducida** y  $k \geq 1$ . En base a esto definimos el siguiente teorema:

**Teorema 18**

$\mathcal{G}$  es una gramática LL( $k$ ) si, y sólo si, para todas dos reglas distintas  $Y \rightarrow \gamma_1, Y \rightarrow \gamma_2 \in P$  y para todo  $S \xRightarrow[\text{lm}]{*} uY\beta$ , se tiene que:

$$\text{first}_k(\gamma_1\beta) \cap \text{first}_k(\gamma_2\beta) = \emptyset$$

**Demostración.** ( $\Rightarrow$ ) Por contrapositivo, supongamos que  $v \in \text{first}_k(\gamma_1\beta) \cap \text{first}_k(\gamma_2\beta)$ . Como  $\mathcal{G}$  es reducida (sin variables inútiles), entonces

$$\begin{array}{ccccccc}
S & \xRightarrow[\text{lm}]{*} & uY\beta & \Rightarrow & u\gamma_1\beta & \xRightarrow[\text{lm}]{*} & uvv_1 \\
& & & \Rightarrow & u\gamma_2\beta & \xRightarrow[\text{lm}]{*} & uvv_2
\end{array}$$

para algún  $v_1, v_2 \in \Sigma^*$ . Como  $\gamma_1 \neq \gamma_2$ , entonces  $\mathcal{G}$  NO es LL( $k$ ).

( $\Leftarrow$ ) Por contrapositivo (de nuevo), supongamos que  $\mathcal{G}$  no es LL( $k$ ). Como  $\mathcal{G}$  no es LL( $k$ ), entonces tenemos derivaciones de la forma:

$$\begin{array}{ccccccc}
S & \xRightarrow[\text{lm}]{*} & uY\beta & \Rightarrow & u\gamma_1\beta & \xRightarrow[\text{lm}]{*} & uv_1 \\
& & & \Rightarrow & u\gamma_2\beta & \xRightarrow[\text{lm}]{*} & uv_2
\end{array}$$

Vemos que  $v_1|_k = v_2|_k = v$ , pero  $\gamma_1 \neq \gamma_2$ . Por lo tanto,  $v \in \text{first}_k(\gamma_1\beta) \cap \text{first}_k(\gamma_2\beta)$ . ■

¿Cómo usamos la caracterización del teorema para demostrar que una gramática es LL( $k$ )? Buscaremos condiciones más simples para verificar si una gramática es LL( $k$ ).

**Definición.**  $\mathcal{G}$  es una gramática LL( $k$ ) **fuerte** si para todas dos reglas distintas  $Y \rightarrow \gamma_1, Y \rightarrow \gamma_2 \in P$  se tiene que:

$$\text{first}_k(\gamma_1) \odot_k \text{follow}_k(Y) \cap \text{first}_k(\gamma_2) \odot_k \text{follow}_k(Y) = \emptyset$$

**Ejemplo 5.16:** Si  $\mathcal{G}$  es  $\text{LL}(k)$  fuerte, entonces  $\mathcal{G}$  es  $\text{LL}(k)$ 

Una gramática  $\mathcal{G}$  que sea  $\text{LL}(k)$  fuerte siempre es  $\text{LL}(k)$ , ya que si definimos dos conjuntos dados por el teorema de  $\text{LL}(k)$  ( $F_1$ ) y la definición de  $\text{LL}(k)$  fuerte ( $F_2$ ), dados por:

$$\begin{aligned} F_1 &= \text{first}_k(\gamma_1\beta) \cap \text{first}_k(\gamma_2\beta) = \text{first}_k(\gamma_1) \odot_k \text{first}_k(\beta) \cap \text{first}_k(\gamma_2) \odot_k \text{first}_k(\beta) \\ F_2 &= \text{first}_k(\gamma_1) \odot_k \text{first}_k(Y) \cap \text{first}_k(\gamma_2) \odot_k \text{first}_k(Y) = \emptyset \end{aligned}$$

Entonces, tenemos que  $F_1 \subseteq F_2$ .

**Ejemplo 5.17:** Si  $\mathcal{G}$  es  $\text{LL}(k)$ , ¿es  $\text{LL}(k)$  fuerte?

La respuesta directa es que no. Con un contraejemplo, tomemos la gramática  $\mathcal{G}$  definida por

$$\begin{aligned} \mathcal{G}: \quad S &\rightarrow aXaa \mid bXba \\ X &\rightarrow b \mid \epsilon \end{aligned}$$

**Recordatorio:**  $\mathcal{G}$  es  $\text{LL}(k)$  si para todas dos reglas distintas  $Y \rightarrow \gamma_1, Y \rightarrow \gamma_2 \in P$  y para todo  $S \xRightarrow[\text{lm}]{*} uY\beta$ , se tiene que

$$\text{first}_k(\gamma_1\beta) \cap \text{first}_k(\gamma_2\beta) = \emptyset$$

♦ Si  $S \xRightarrow[\text{lm}]{*} aXaa$ , entonces  $\text{first}_2(baa) \cap \text{first}_2(aa) = \emptyset$ .

♦ Si  $S \xRightarrow[\text{lm}]{*} bXba$ , entonces  $\text{first}_2(baa) \cap \text{first}_2(ba) = \emptyset$

Por lo tanto,  $\mathcal{G}$  es  $\text{LL}(2)$ .

**Recordatorio:**  $\mathcal{G}$  es una gramática  $\text{LL}(k)$  fuerte si para todas dos reglas distintas  $Y \rightarrow \gamma_1, Y \rightarrow \gamma_2 \in P$  se tiene que:

$$\text{first}_k(\gamma_1) \odot_k \text{follow}_k(Y) \cap \text{first}_k(\gamma_2) \odot_k \text{follow}_k(Y) = \emptyset$$

Si vemos  $X \rightarrow b$  y  $X \rightarrow \epsilon$ :

$$\begin{aligned} &\text{first}_2(b) \odot_2 \text{follow}_2(X) \cap \text{first}_2(\epsilon) \odot_2 \text{follow}_2(X) \\ &= \{b\} \odot_2 \{aa, ba\} \cap \{\epsilon\} \odot_2 \{aa, ba\} \\ &= \{ba, bb\} \cap \{aa, ba\} \\ &= \{ba\} \quad \text{y por ende } \mathcal{G} \text{ no es } \text{LL}(2) \text{ fuerte.} \end{aligned}$$

¿Qué pasa con el caso  $\text{LL}(1)$ ? Supongamos que  $\mathcal{G}$  es  $\text{LL}(1)$  y  $Y \rightarrow \gamma_1, Y \rightarrow \gamma_2 \in P$  son reglas distintas.

1. Si  $\epsilon \notin \text{first}_1(\gamma_1)$  y  $\epsilon \notin \text{first}_1(\gamma_2)$ , entonces, por la caracterización de  $\text{LL}(1)$ :

$$\begin{aligned} \emptyset &= \text{first}_1(\gamma_1\beta) \cap \text{first}_1(\gamma_2\beta) \\ &= \text{first}_1(\gamma_1) \cap \text{first}_1(\gamma_2) \\ &= \text{first}_1(\gamma_1) \odot_1 \text{follow}_1(Y) \cap \text{first}_1(\gamma_2) \odot_1 \text{follow}_1(Y) \end{aligned}$$

2. Si  $\epsilon \in \text{first}_1(\gamma_1)$  y  $\epsilon \notin \text{first}_1(\gamma_2)$ , entonces, por la caracterización de  $\text{LL}(1)$ :

$$\begin{aligned} \emptyset &= \text{first}_1(\gamma_1\beta) \cap \text{first}_1(\gamma_2\beta) \\ &= \text{first}_1(\gamma_1\beta) \cap \text{first}_1(\gamma_2) \\ &= \text{first}_1(\gamma_1\beta) \cap \text{first}_1(\gamma_2\beta') \end{aligned}$$

para todo  $\beta' \in (V \cup \Sigma)^*$ . Por lo tanto:

$$\begin{aligned} & \text{first}_1(\gamma_1) \odot_1 \text{follow}_1(Y) \cap \text{first}_1(\gamma_2) \odot_1 \text{follow}_1(Y) \\ &= \bigcup_{S \xrightarrow[\text{lm}]{\neq} uY\beta} \text{first}_1(\gamma_1\beta) \cap \bigcup_{S \xrightarrow[\text{lm}]{\neq} uY\beta'} \text{first}_1(\gamma_2\beta') = \emptyset \end{aligned}$$

Por lo tanto, establecemos el siguiente teorema.

#### Teorema 19

Una gramática  $\mathcal{G}$  es  $LL(1)$  si, y sólo si,  $\mathcal{G}$  es  $LL(1)$  **fuerte**, esto es, para todas dos reglas distintas  $Y \rightarrow \gamma_1, Y \rightarrow \gamma_2 \in P$ :

$$\text{first}_1(\gamma_1) \odot_1 \text{follow}_1(Y) \cap \text{first}_1(\gamma_2) \odot_1 \text{follow}_1(Y) = \emptyset$$

La condición del teorema anterior se puede verificar en **tiempo polinomial** en  $\mathcal{G}$ .

### 5.5. Parsing con gramáticas $LL(k)$

#### 5.5.1. Algunas consideraciones

Considere la siguiente gramática  $\mathcal{G}$ :

$$\begin{aligned} S &\rightarrow Xa \mid Xb \\ X &\rightarrow c \end{aligned}$$

¿Es esta gramática del tipo  $LL(1)$ ? Podemos ver que  $\text{first}_1(\gamma_1\beta) = \{c\}$  y  $\text{first}_1(\gamma_2\beta) = \{c\}$ , con  $\gamma_1 = Xa$ ,  $\gamma_2 = Xb$  y  $\beta = \epsilon$ . Por lo tanto su intersección no es vacía y entonces  $\mathcal{G}$  no es  $LL(1)$ . ¿Podemos establecer una solución para este problema?

**Factorización.** En general, si tenemos una regla:

$$X \rightarrow \gamma\alpha_1 \mid \gamma\alpha_2$$

siempre podemos “**factorizar**” la regla manteniendo la semántica, como:

$$\begin{aligned} X &\rightarrow \gamma X' \\ X' &\rightarrow \alpha_1 \mid \alpha_2 \end{aligned}$$

Considere ahora la siguiente gramática  $\mathcal{G}$ :

$$E \rightarrow E * E \mid n$$

¿Es esta gramática del tipo  $LL(1)$ ? ¿ $LL(k)$ ? Pues no es ninguna. El problema con esta gramática es su recursividad, en específico, por la izquierda.

**Definición.** Una gramática  $\mathcal{G}$  se dice **recursiva por la izquierda** si existe  $X \in V$  tal que:

$$X \xRightarrow{+} X\gamma \quad \text{para algún } \gamma \in (V \cup \Sigma)^*$$

#### Teorema 20

Si  $\mathcal{G} = (V, \Sigma, P, S)$  es una gramática reducida y recursiva por la izquierda, entonces  $\mathcal{G}$  NO es  $LL(k)$  para todo  $k \geq 1$ .

**Demostración.** Por simplicidad, suponga que  $X \rightarrow X\beta \in P$  y  $X \rightarrow w \in P$ .

Como  $\mathcal{G}$  es reducida, entonces existe una derivación  $S \xRightarrow[\text{lm}]{*} uX\gamma$ :

$$S \xRightarrow[\text{lm}]{*} uX\gamma \xRightarrow[\text{lm}]{n\text{-veces}} uX\beta^n\gamma$$

Por **contradicción**, suponga que  $\mathcal{G}$  es  $\text{LL}(k)$ . Por lo tanto:

$$\text{first}_k(X\beta^{n+1}\gamma) \cap \text{first}_k(w\beta^n\gamma) = \emptyset$$

Suponga que  $\beta \xRightarrow{*} v \in \Sigma^*$  y  $\gamma \xRightarrow{*} v' \in \Sigma^*$ . Con  $n = k$ , tendremos que

$$(wv^kv')|_k \in \text{first}_k(X\beta^{k+1}\gamma) \cap \text{first}_k(w\beta^k\gamma) \rightarrow \leftarrow \text{ (¡contradicción! el conjunto no es vacío)}$$

■

Hablemos de recursión **inmediata** por la izquierda. Suponga que existe  $X \in V$  tal que:

$$X \rightarrow X\alpha_1 \mid \cdots \mid X\alpha_m \mid \beta_1 \mid \cdots \mid \beta_n$$

¿Cómo podemos **eliminar** la recursión inmediata por la izquierda? Consideramos la misma gramática pero **cambiando** las reglas de  $X$  por:

$$\begin{aligned} X &\rightarrow \beta_1 X' \mid \cdots \mid \beta_n X' \\ X' &\rightarrow \alpha_1 X' \mid \cdots \mid \alpha_m X' \mid \epsilon \end{aligned}$$

#### Ejemplo 5.18: Eliminando recursión inmediata

$$\begin{array}{lcl} S & \rightarrow & Xa \mid b \\ X & \rightarrow & Xc \mid d \end{array} \quad \left| \quad \begin{array}{lcl} S & \rightarrow & Xa \mid b \\ X & \rightarrow & dX' \\ X' & \rightarrow & cX' \mid \epsilon \end{array}$$

#### Teorema 21

Sea  $\mathcal{G}$  una gramática tal que existe  $X \in V$ :

$$X \rightarrow X\alpha_1 \mid \cdots \mid X\alpha_m \mid \beta_1 \mid \cdots \mid \beta_n$$

Sea  $\mathcal{G}'$  la misma gramática  $\mathcal{G}$  pero cambiando las reglas de  $X$  por:

$$\begin{aligned} X &\rightarrow \beta_1 X' \mid \cdots \mid \beta_n X' \\ X' &\rightarrow \alpha_1 X' \mid \cdots \mid \alpha_m X' \mid \epsilon \end{aligned}$$

Entonces  $\mathcal{L}(\mathcal{G}) = \mathcal{L}(\mathcal{G}')$

**Demostración.** Una derivación por la izquierda de  $X$  en  $\mathcal{G}$ :

$$X \xRightarrow[\text{lm}]{} X\alpha_{i_1} \xRightarrow[\text{lm}]{} X\alpha_{i_2}\alpha_{i_1} \xRightarrow[\text{lm}]{} \cdots \xRightarrow[\text{lm}]{} X\alpha_{i_p}\alpha_{i_{p-1}}\cdots\alpha_{i_1} \xRightarrow[\text{lm}]{} \beta_j\alpha_{i_p}\alpha_{i_{p-1}}\cdots\alpha_{i_1}$$

Una derivación por la derecha de  $X$  en  $\mathcal{G}'$  **equivalente**:

$$X \xRightarrow[\text{rm}]{} \beta_j X' \xRightarrow[\text{rm}]{} \beta_j \alpha_{i_p} X' \xRightarrow[\text{rm}]{} \cdots \xRightarrow[\text{rm}]{} \beta_j \alpha_{i_p} \cdots \alpha_{i_2} \alpha_{i_1} X' \xRightarrow[\text{rm}]{} \beta_j \alpha_{i_p} \alpha_{i_{p-1}} \cdots \alpha_{i_1}$$

■



Ahora, ¿qué pasa si la recursión por la izquierda es **no-inmediata**? Considere la siguiente gramática **recursiva por la izquierda**:

$$S \rightarrow Xa \mid b$$

$$X \rightarrow Yc$$

$$Y \rightarrow Xd \mid e$$

¿Cómo eliminamos la recursión por la izquierda no-inmediata?

**Estrategia.** Dado  $V = \{X_1, \dots, X_n\}$ , removemos la recursión inductivamente en  $n$ , tal que, en cada paso  $i$  de la inducción, se cumpla que para todo  $i, j \leq n$ :

$$\text{si } X_i \rightarrow X_j \alpha, \text{ entonces } i < j$$

**input :** Gramática  $\mathcal{G} = (V, \Sigma, P, S)$  y  $V = \{X_1, \dots, X_n\}$

**output:** Gramática  $\mathcal{G}$  sin recursión por la izquierda

**Function** EliminarRecursion( $\mathcal{G}$ ):

$P' := P$

**for**  $i = 1$  **to**  $n$  **do**

**for**  $j = 1$  **to**  $i - 1$  **do**

**foreach**  $X_i \rightarrow X_j \gamma \in P'$  **do**

**foreach**  $X_j \rightarrow \alpha \in P'$  **do**

$P' := P' \cup \{X_i \rightarrow \alpha \gamma\}$

$P' := P' - \{X_i \rightarrow X_j \gamma\}$

Remover recursión inmediata para  $X_i$  en  $P'$  (si existe)

$V' := \{X_1, \dots, X_n\} \cup \{X'_1, \dots, X'_n\}$

**return**  $(V', \Sigma, P', S)$

Queda como ejercicio propuesto al lector demostrar la correctitud del algoritmo.

#### Ejemplo 5.19: Eliminando recursión

$$E \rightarrow E + T \mid T$$

$$T \rightarrow T * F \mid F$$

$$F \rightarrow (E) \mid n$$

Eliminando la **recursión inmediata** de  $E$ :

$$E \rightarrow TE'$$

$$E' \rightarrow +TE' \mid \epsilon$$

$$T \rightarrow T * F \mid F$$

$$F \rightarrow (E) \mid n$$

Eliminando la **recursión inmediata** de  $T$ :

$$E \rightarrow TE'$$

$$E' \rightarrow +TE' \mid \epsilon$$


$$T \rightarrow FT'$$

$$T' \rightarrow *FT' \mid \epsilon$$

$$F \rightarrow (E) \mid n$$

**Conclusión.** Es posible eliminar la recursividad por la izquierda, pero esto **NO asegura** que el resultado sea una gramática  $LL(k)$  para algún  $k$ .

### 5.5.2. Parsing de $LL(k)$



**Figura 9:** Máquina de parsing

**Definición.** Sea  $\Sigma$  un alfabeto finito. Se definen los siguientes conjuntos de palabras:

- ♦  $\dot{\Sigma} = \Sigma^* \times \Sigma^*$
- ♦  $\dot{\Sigma}^{\leq k} = \{(u, v) \in \dot{\Sigma} \mid |uv| \leq k\}$
- ♦  $\dot{\Sigma}_{\#}^{\leq k} = \{(u, v) \in \dot{\Sigma} \mid |uv| \leq k\} \cup \{(u, v\#) \mid (u, v) \in \dot{\Sigma} \mid |uv| < k\}$

**Notación.** En vez de usar  $(u, v) \in \dot{\Sigma}_{\#}^{\leq k}$ , escribiremos  $u.v \in \dot{\Sigma}_{\#}^{\leq k}$ . El par  $\epsilon.\epsilon$  lo denotaremos solamente por  $\epsilon$ .

**Definición.** Un transductor apilador con  $k$ -lookahead ( $k$ -PDT) es una tupla:

$$\mathcal{T} = (Q, \Sigma, \Omega, \Delta, q_0, F)$$

- ♦  $Q$  es un conjunto finito de estados.
- ♦  $\Sigma$  es el alfabeto de input.
- ♦  $\Omega$  es el alfabeto de output.
- ♦  $\Delta \subseteq Q^+ \times \dot{\Sigma}_{\#}^{\leq k} \times (\Omega \cup \{\epsilon\}) \times Q^*$  es la relación de transición.
- ♦  $q_0 \in Q$  es un conjunto de estados iniciales.
- ♦  $F \subseteq Q$  es el conjunto de estados finales.

**Definición.** Una **configuración** de  $\mathcal{T}$  es una tupla:

$$(q_1 \dots q_k, w, o) \in (Q^+, \Sigma^* \cdot \{\#\}, \Omega^*)$$

♦  $q_1 \dots q_k$  es el contenido del stack con  $q_1$  el tope del stack.

♦  $w$  es el contenido del input.

♦  $o$  es el contenido del output.

Decimos que una configuración:

♦  $(q_0, w\#, \epsilon)$  es **inicial** y

♦  $(q_f, \#, o)$  es **final** si  $q_f \in F$ .

**Definición.** Se define la relación  $\vdash_{\mathcal{T}}$  de **siguiente-paso** entre configuraciones de  $\mathcal{T}$ :

$$(\gamma_1, w_1, o_1) \vdash_{\mathcal{T}} (\gamma_2, w_2, o_2)$$

si, y sólo si, existe  $(\alpha, u.v, a, \beta) \in \Delta$ ,  $\gamma \in \Gamma^*$  y  $w \in \Sigma^* \cdot \{\#\}$  tal que:

♦ **Stack:**  $\gamma_1 = \alpha \cdot \gamma$  y  $\gamma_2 = \beta \cdot \gamma$

♦ **Look-ahead:**  $w_1 = u \cdot v \cdot w$  y  $w_2 = v \cdot w$

♦ **Output:**  $o_2 = o_1 \cdot a$

Se define  $\vdash_{\mathcal{T}}^*$  como la clausura **refleja y transitiva** de  $\vdash_{\mathcal{T}}$ .

**Definición.**  $\mathcal{T}$  **entrega**  $o$  con **input**  $w$  si existe una configuración inicial  $(q_0, w \cdot \#, \epsilon)$  y una configuración final  $(q_f, \#, o)$  tal que:

$$(q_0, w \cdot \#, \epsilon) \vdash_{\mathcal{T}}^* (q_f, \#, o)$$

Se define la función  $\llbracket \mathcal{T} \rrbracket : \Sigma^* \rightarrow 2^{\Omega^*}$ :

$$\llbracket \mathcal{T} \rrbracket(w) = \{o \in \Omega^* \mid \mathcal{T} \text{ entrega } o \text{ con input } w\}$$

**Definición.**  $\mathcal{T}$  es **determinista** si para todo  $(\alpha_1, u_1.v_1, a_1, \beta_1), (\alpha_2, u_2.v_2, a_2, \beta_2) \in \Delta$  con  $(\alpha_1, u_1.v_1, a_1, \beta_1) \neq (\alpha_2, u_2.v_2, a_2, \beta_2)$  se cumple que

$$\alpha_1 \text{ NO es prefijo de } \alpha_2 \quad \text{o} \quad u_1.v_1 \text{ NO es prefijo de } u_2.v_2.$$

“Para cualquier configuración  $(\gamma, w, o)$  existe **a lo más** una configuración  $(\gamma', w', o)$  tal que  $(\gamma, w, o) \vdash_{\mathcal{T}}^* (\gamma', w', o)$ ”

La **ventaja** de un  $k$ -PDT determinista es que nos aseguramos de que siempre obtenemos un solo output para cada input (el no-determinismo nos podría generar muchos outputs distintos).

**Construcción del parser.** Sea  $\mathcal{G} = (V, \Sigma, P, S)$  una gramática  $\text{LL}(k)$  fuerte. Se define el  $k$ -PDT para  $\mathcal{G}$ :

$$\mathcal{T}[\mathcal{G}] = \left( V \cup \Sigma \cup \{q_0, q_f\}, \Sigma, \underbrace{P}_{\Omega}, \Delta, q_0, \{q_f\} \right)$$

La relación de transición  $\Delta$  se define como:

**Inicio:**  $(q_0, \epsilon, \epsilon, S \cdot q_f)$

**Reducir:**  $(a, a., \epsilon, \epsilon)$  para cada  $a \in \Sigma$

**Expandir:**  $(X, .u, p, \gamma)$

para cada  $p := (X \rightarrow \gamma) \in P$  tal que  $u \in \text{first}_k(\gamma) \odot_k \text{follow}_k(X)$

**Propiedades.**  $\mathcal{T}[\mathcal{G}]$  tiene las siguientes propiedades:

1.  $\mathcal{T}[\mathcal{G}]$  es un  $k$ -PDT **determinista** si, y sólo si,  $\mathcal{G}$  es  $\text{LL}(k)$  fuerte.
2. Si  $w \notin \mathcal{L}(\mathcal{G})$  entonces  $\llbracket \mathcal{T} \rrbracket(w) = \emptyset$ .
3. Si  $w \in \mathcal{L}(\mathcal{G})$  entonces  $\llbracket \mathcal{T} \rrbracket(w) = \{r_1 \dots r_m\}$  es una derivación por la izquierda de  $\mathcal{G}$  sobre  $w$ .

**Algoritmo.** Para una gramática  $\text{LL}(k)$   $\mathcal{G}$  y una palabra  $w \in \Sigma^*$ :

1. Construya el  $k$ -PDT determinista  $\mathcal{T}[\mathcal{G}]$  a partir de  $\mathcal{G}$ .
2. Ejecute  $\mathcal{T}[\llbracket \mathcal{G} \rrbracket]$  sobre  $w$ .

Como  $\mathcal{T}[\mathcal{G}]$  es determinista, entonces el algoritmo toma **tiempo lineal** en  $w$ .

**Tabla predictiva para  $\text{LL}(k)$  fuerte.** Sea  $\mathcal{G} = (V, \Sigma, P, S)$  una gramática  $\text{LL}(k)$  fuerte. Para cada  $u \in \Sigma^k \cup \Sigma^{<k} \cdot \{\#\}$ , se define  $M[X, u] \in (V \cup \Sigma)^* \cup \{\text{ERROR}\}$ :

$$M[X, u] = \begin{cases} \gamma & \text{si } X \rightarrow \gamma \in P \text{ y } u \in \text{first}_k(\gamma) \odot_k \text{follow}_k(X) \\ \text{ERROR} & \text{en otro caso.} \end{cases}$$

El computo de la tabla predictiva puede tomar **tiempo exponencial** en  $|\mathcal{G}|$  y  $k$ .

**Caso especial: tabla predictiva para  $\text{LL}(1)$ .** Sea  $\mathcal{G} = (V, \Sigma, P, S)$  una gramática  $\text{LL}(1)$  fuerte. Para cada  $a \in \Sigma \cup \{\#\}$ , se define  $M[x, a] \in (V \cup \Sigma)^* \cup \{\text{ERROR}\}$ :

$$M[X, a] = \begin{cases} \gamma & \text{si } X \rightarrow \gamma \in P \text{ y } a \in \text{first}_1(\gamma) \\ \gamma & \text{si } X \rightarrow \gamma \in P, \epsilon \in \text{first}_1(\gamma) \text{ y } a \in \text{follow}_1(X) \\ \text{ERROR} & \text{en otro caso.} \end{cases}$$

Este cálculo se puede hacer en tiempo  $\mathcal{O}(|V| \cdot |P|)$ .

Ejemplo 5.20: Tabla predictiva

$E$	$\rightarrow TE'$	$\text{first}_1(E) = \{ (, \text{id} \}$	$\text{first}_1(E') = \{ +, \epsilon \}$
$E'$	$\rightarrow +TE' \mid \epsilon$	$\text{first}_1(T) = \{ (, \text{id} \}$	$\text{first}_1(T') = \{ *, \epsilon \}$
$T$	$\rightarrow FT'$	$\text{first}_1(F) = \{ (, \text{id} \}$	
$T'$	$\rightarrow *FT' \mid \epsilon$	$\text{follow}_1(E) = \{ \}, \# \}$	$\text{follow}_1(E') = \{ \}, \# \}$
$F$	$\rightarrow (E) \mid \text{id}$	$\text{follow}_1(T) = \{ +, \}, \# \}$	$\text{follow}_1(T') = \{ +, \}, \# \}$
		$\text{follow}_1(F) = \{ +, *, \}, \# \}$	

	<b>id</b>	<b>+</b>	<b>*</b>	<b>(</b>	<b>)</b>	<b>#</b>
E	$TE'$	ERROR	ERROR	$TE'$	ERROR	ERROR
E'	ERROR	$+TE'$	ERROR	ERROR	$\epsilon$	$\epsilon$
T	$FT'$	ERROR	ERROR	$FT'$	ERROR	ERROR
T'	ERROR	$\epsilon$	$*FT'$	ERROR	$\epsilon$	$\epsilon$
F	<b>id</b>	ERROR	ERROR	$(E)$	ERROR	ERROR

## 6. Extracción de información

### 6.1. Extracción

### 6.2. Enumeración de resultados: Autómatas con anotaciones